APLICAÇÃO DE ENGENHARIA DE DADOS E BUSINESS INTELLIGENCE NA ANÁLISE DE INDICADORES EDUCACIONAIS DA EDUCAÇÃO BÁSICA BRASILEIRA

Milton Rafael De Souza Garcia

Universidade do Estado de Minas Gerais
Unidade Ituiutaba
Graduação em Sistemas de Informação

Ituiutaba
2026

Milton Rafael De Souza Garcia

APLICAÇÃO DE ENGENHARIA DE DADOS E BUSINESS INTELLIGENCE NA ANÁLISE DE INDICADORES EDUCACIONAIS DA EDUCAÇÃO BÁSICA BRASILEIRA

Trabalho de Conclusão de Curso de Graduação apresentado ao Curso de Graduação em Sistemas de Informação da Universidade do Estado de Minas Gerais - Unidade Ituiutaba, como parte dos requisitos para a obtenção do título de Bacharel em Sistemas de Informação.

Área de concentração: Sistemas de Informação

Orientador: Anderson de Melo Valadão

Ituiutaba
2026

Dedico este trabalho à minha esposa, Alane de Cássia Alves Ferreira, professora e inspiração desta pesquisa. Seu apoio, sua confiança e sua presença foram essenciais em minha caminhada acadêmica. Minha formação é, em grande parte, fruto do seu incentivo, do seu cuidado e da força que você sempre me transmitiu. Esta conquista também pertence a você.

Agradecimentos

Agradeço, primeiramente, a Deus, pela força, saúde e perseverança concedidas ao longo desta caminhada.

À minha esposa, Alane de Cássia Alves Ferreira, professora, companheira e inspiração deste trabalho, agradeço pelo apoio constante, pelo incentivo nos momentos difíceis e por acreditar em mim. Sua presença foi essencial para que eu chegasse até aqui. Agradeço à minha família, pelo apoio, pela compreensão e por fazer parte da minha trajetória de vida e formação.

Ao meu professor orientador, Anderson, agradeço pela orientação, pelas contribuições e pelo acompanhamento durante o desenvolvimento deste trabalho.

Aos professores da Universidade do Estado de Minas Gerais — UEMG, especialmente aos docentes do curso de Sistemas de Informação, agradeço pelos conhecimentos compartilhados ao longo da minha formação acadêmica. Cada disciplina, orientação, diálogo e desafio proposto contribuiu para a construção dos saberes que tornaram possível a realização deste trabalho.

Por fim, agradeço à Universidade do Estado de Minas Gerais — UEMG, pela oportunidade de formação e por fazer parte desta importante etapa da minha vida acadêmica e profissional.

"Sem dados, você é apenas mais uma pessoa com uma opinião."
W. Edwards Deming

Resumo

Este trabalho tem como objetivo desenvolver e analisar uma arquitetura reprodutível de Engenharia de Dados e Business Intelligence para integrar indicadores educacionais da Educação Básica brasileira. Foram utilizadas bases públicas do Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP): Índice de Desenvolvimento da Educação Básica (IDEB), Sistema de Avaliação da Educação Básica (SAEB), Taxas de Rendimento Escolar, Taxa de Distorção Idade-Série (TDI) e, como análise complementar, Prova Nacional Docente (PND) 2025. A metodologia implementou em Python um pipeline de ingestão, transformação e carga organizado nas camadas Raw, Bronze, Silver e Gold, com auditorias, validações de qualidade, inventário das fontes e hashes SHA-256 para identificação dos insumos. A aquisição dos arquivos oficiais também foi automatizada, incluindo seleção das edições, extração dos pacotes, organização da camada Raw e verificação dos insumos. A Gold foi estruturada como modelo dimensional e disponibilizada em arquivos Parquet consumidos pelo Power BI, no qual foram definidos os relacionamentos, as medidas DAX e os dashboards. A análise histórica foi padronizada em nível de Unidade Federativa para o período de 2007 a 2023, considerando IDEB, SAEB, Rendimento Escolar e TDI; a PND foi analisada separadamente em 2025. O processo resultou em cinco tabelas fato, cinco dimensões e controles de qualidade sobre esquema, domínio, cobertura temporal, duplicidade, integridade referencial e correspondência entre as camadas. Os resultados mostram que a arquitetura permite integrar fontes heterogêneas, preservar a rastreabilidade das transformações e disponibilizar dados consistentes para exploração analítica. Conclui-se que a combinação entre pipeline reprodutível e Business Intelligence contribui para transformar bases públicas dispersas em informações estruturadas e verificáveis, sem atribuir causalidade às relações observadas.

Palavras-chave: Engenharia de Dados. Pipelines de Dados. Indicadores Educacionais. Reprodutibilidade de Dados. Business Intelligence.

Abstract

This work aims to develop and analyze a reproducible Data Engineering and Business Intelligence architecture for integrating educational indicators of Brazilian Basic Education. Public datasets from the National Institute for Educational Studies and Research Anísio Teixeira (INEP) were used: the Basic Education Development Index (IDEB), the Basic Education Assessment System (SAEB), School Flow Rates, the Age-Grade Distortion Rate (TDI), and, as a complementary analysis, the 2025 National Teacher Exam (PND). The methodology implemented a Python ingestion, transformation, and loading pipeline organized into Raw, Bronze, Silver, and Gold layers, with audits, data quality validations, a source inventory, and SHA-256 checksums for input identification. The acquisition of official files was also automated, including edition selection, archive extraction, Raw layer organization, and input verification. The Gold layer was structured as a dimensional model and stored in Parquet files consumed by Power BI, where relationships, DAX measures, and dashboards were defined. The historical analysis was standardized at the Federative Unit level for the 2007–2023 period, covering IDEB, SAEB, School Flow Rates, and TDI; PND was analyzed separately for 2025. The process produced five fact tables, five dimensions, and quality controls for schema, domain, temporal coverage, duplicates, referential integrity, and agreement between layers. The results show that the architecture integrates heterogeneous sources, preserves transformation traceability, and provides consistent data for analytical exploration. It is concluded that combining a reproducible pipeline and Business Intelligence helps transform scattered public datasets into structured and verifiable information, without assigning causality to the observed relationships.

Keywords: Data Engineering. Data Pipelines. Educational Indicators. Data Reproducibility. Business Intelligence.

Lista de ilustrações

Figura 1 – Percurso dos dados, da aquisição nas fontes oficiais ao consumo analítico. 41
Figura 2 – Modelo dimensional atual consumido pelo Power BI. 47
Figura 3 – Página de metodologia e arquitetura do projeto no Power BI. 49
Figura 4 – Panorama dos indicadores da Educação Básica. 54
Figura 5 – Desempenho educacional por Unidade Federativa no recorte exibido no dashboard. 56
Figura 6 – Aprendizagem e fluxo escolar por Unidade Federativa. 57
Figura 7 – Variação dos indicadores por Unidade Federativa no intervalo 2007–2023. 58
Figura 8 – Distorção idade-série por Unidade Federativa e etapa de ensino. 59
Figura 9 – Resultados da Prova Nacional Docente de 2025. 60

Lista de tabelas

Tabela 1 – Comparação dos trabalhos correlatos 37
Tabela 2 – Síntese dos desafios e decisões de harmonização por indicador e período. 43
Tabela 3 – Medidas DAX implementadas no modelo semântico. 48
Tabela 4 – Cardinalidades validadas da camada Gold. 53
Tabela 5 – Mapeamento físico do Rendimento Escolar por período. 72
Tabela 6 – Mapeamento físico da TDI por período. 74
Tabela 7 – Mapeamento do IDEB para a Silver. 75
Tabela 8 – Mapeamento histórico do SAEB. 76
Tabela 9 – Mapeamento físico dos campos utilizados da PND 2025. 77
Tabela 10 – Mapeamento de nomes das Unidades Federativas para siglas. 79
Tabela 11 – Harmonização da rede pública por fonte. 80
Tabela 12 – Categorias analíticas padronizadas. 81
Tabela 13 – Códigos de área da PND 2025. 82
Tabela 14 – Códigos categóricos da PND preservados na Silver. 82
Tabela 15 – Classificação de desempenho derivada de `NT_OBJ`. 83
Tabela 16 – Tratamento de ausência e precisão por indicador. 83
Tabela 17 – Critérios de seleção e dados fora do recorte analítico. 86
Tabela 18 – Composição da população analítica da PND 2025. 87
Tabela 19 – Cardinalidades esperadas das tabelas analíticas. 87
Tabela 20 – Estruturas preservadas na camada Bronze. 88
Tabela 21 – Dimensões de qualidade verificadas ao longo do pipeline. 90
Tabela 22 – Controles específicos das tabelas Silver. 91
Tabela 23 – Metadados de proveniência preservados na Silver. 92

Sumário

1 INTRODUÇÃO 21
1.1 Motivação 22
1.2 Objetivos e Desafios da Pesquisa 23
1.3 Contribuições 24
1.4 Organização do trabalho 25

2 FUNDAMENTAÇÃO TEÓRICA 27
2.1 Engenharia de Dados 27
2.2 Processo ETL (Extract, Transform, Load) 28
2.3 Arquitetura em camadas e reprodutibilidade 28
2.4 Data Warehouse e Modelagem Dimensional 30
2.5 Business Intelligence e Visualização de Dados 30
2.6 Indicadores Educacionais Brasileiros 31

3 ESTADO DA ARTE 33
3.1 Busca por trabalhos correlatos 33
3.2 Soares et al. (2021) 34
3.3 Ilha e Moreira Junior (2021) 35
3.4 Wanderley (2021) 35
3.5 Martins Filho (2025) 36
3.6 Análise comparativa dos trabalhos 36
3.7 Contribuições do trabalho 37

4 METODOLOGIA 39
4.1 Classificação da pesquisa 39
4.2 Fontes e coleta dos dados 40
4.3 Arquitetura e processo de ingestão 40
4.4 Transformação, linhagem e validação 41

4.4.1 Desafios de harmonização histórica 42
4.4.2 Tratamento da base IDEB 44
4.4.3 Tratamento da base SAEB 44
4.4.4 Tratamento da base de Rendimento Escolar 44
4.4.5 Tratamento da base de Distorção Idade-Série 45
4.4.6 Tratamento da base PND 2025 45
4.5 Modelagem dos dados 46
4.6 Desenvolvimento das métricas analíticas 48
4.7 Desenvolvimento dos dashboards 48
4.8 Notebooks, testes e automação 50
4.9 Ferramentas utilizadas 50
4.10 Limitações metodológicas 51

5 RESULTADOS E DISCUSSÃO 53
5.1 Estrutura final do modelo analítico 53
5.2 Panorama geral dos indicadores educacionais 54
5.3 Desempenho educacional por Unidade Federativa 55
5.4 Aprendizagem e fluxo escolar 56
5.5 Variação dos indicadores por Unidade Federativa 57
5.6 Análise da Taxa de Distorção Idade-Série 58
5.7 Resultados da PND 2025 59
5.8 Limitações observadas nos resultados 60

6 CONCLUSÃO 61
6.1 Principais Contribuições 62
6.2 Trabalhos Futuros 63
6.3 Perspectivas de produção bibliográfica 63

REFERÊNCIAS 65

APÊNDICES 69

APÊNDICE A – MAPEAMENTO HISTÓRICO DOS LAYOUTS 71
A.1 Rendimento Escolar 71
A.2 Taxa de Distorção Idade-Série 73
A.3 IDEB 75
A.4 SAEB 75
A.5 PND 2025 77

APÊNDICE B – DICIONÁRIO DE HARMONIZAÇÃO DE CATEGORIAS 79
B.1 Unidades Federativas 79
B.2 Rede pública e localização 80
B.3 Etapas, indicadores e disciplinas 81
B.4 Códigos da PND 2025 81
B.4.1 Áreas da prova 81
B.4.2 Inscrição, aplicação e presença 82
B.4.3 Padrão de desempenho 83
B.5 Marcadores de ausência e conversão numérica 83

APÊNDICE C – CRITÉRIOS DE INCLUSÃO E EXCLUSÃO . . 85
C.1 Recortes por indicador 85
C.2 População analítica da PND 87
C.3 Cardinalidades e transformação do grão 87
C.4 Contagens preservadas na Bronze 88
C.5 Colunas de proveniência e projeção Gold 88

APÊNDICE D – CONTROLES DE QUALIDADE E RASTREABILIDADE 89
D.1 Controles por camada 89
D.2 Contratos por indicador 91
D.3 Campos de rastreabilidade 92
D.4 Falha explícita 92
D.5 Validação independente e limites da garantia 92

Capítulo 1

Introdução

Nas últimas décadas, a produção e o armazenamento de dados passaram a ocupar papel central em diferentes áreas da sociedade. Entretanto, a disponibilidade de grandes volumes de dados, por si só, não garante sua transformação em informação útil ou conhecimento. Loh (2014) distingue dados, informação e conhecimento e destaca que sistemas de informação e processos de Business Intelligence podem apoiar a tomada de decisão ao organizar, analisar e contextualizar os dados disponíveis. Nesse contexto, torna-se necessário aplicar técnicas capazes de coletar, preparar, integrar, tratar e apresentar informações de maneira compreensível e analiticamente útil.

No contexto educacional brasileiro, essa realidade também se faz presente. O Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) disponibiliza diferentes bases públicas relacionadas à Educação Básica, entre elas o Índice de Desenvolvimento da Educação Básica (IDEB) (INEP, 2024), o Sistema de Avaliação da Educação Básica (SAEB) (INEP, 2025a), as Taxas de Rendimento Escolar (INEP, 2025b) e a Taxa de Distorção Idade-Série (TDI) (INEP, 2026). Em conjunto, essas fontes permitem observar dimensões como desempenho dos estudantes, fluxo escolar, aprovação, reprovação, abandono e distorção idade-série. Além desses indicadores históricos, este trabalho também considera a Prova Nacional Docente (PND) 2025 como base complementar de análise (Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2025b), especialmente por permitir observar informações relacionadas ao desempenho de participantes em diferentes áreas de formação docente.

Apesar da relevância dessas informações, sua utilização ainda apresenta desafios. Os dados encontram-se distribuídos em diferentes arquivos, períodos históricos, formatos e estruturas. Além disso, as bases possuem nomenclaturas, códigos e formas de organização distintas, o que dificulta análises integradas entre indicadores, anos, unidades federativas, redes de ensino, etapas escolares e demais categorias de análise. As fontes também variam quanto ao nível de agregação e à forma de apresentação. Neste trabalho, foram priorizados resultados oficiais agregados por Unidade Federativa sempre que disponíveis; microdados e arquivos em outros níveis foram preservados para auditoria ou empregados quando

necessários. Assim, uma análise mais ampla da Educação Básica exige não apenas acesso aos dados, mas também processos consistentes de preparação, transformação, validação e modelagem.

Diante desse cenário, este trabalho delimita-se à análise da aplicação de técnicas de Engenharia de Dados e Business Intelligence na integração e visualização de indicadores educacionais brasileiros disponibilizados pelo INEP, considerando o período de 2007 a 2023 para as bases históricas de IDEB, SAEB, Rendimento Escolar e Distorção Idade-Série. A PND 2025 foi incorporada como base complementar, não compondo a série histórica principal, mas ampliando as possibilidades de análise por meio de informações relacionadas às notas, acertos, áreas de formação e códigos dos municípios de aplicação da prova.

A pesquisa concentra-se na organização das bases de IDEB, SAEB, Rendimento Escolar, Distorção Idade-Série e PND 2025, com a finalidade de compreender como essas informações podem ser estruturadas em um ambiente analítico capaz de favorecer interpretações históricas, comparativas e visuais. Para garantir maior consistência entre as bases, a análise histórica foi padronizada principalmente em nível de Unidade Federativa (UF), contemplando Anos Iniciais e Anos Finais do Ensino Fundamental. O Ensino Médio não compôs o recorte analítico desenvolvido neste trabalho.

A relevância deste estudo está no fato de que dados educacionais públicos, quando analisados de forma isolada ou fragmentada, podem limitar a compreensão da realidade educacional. Ao integrar diferentes indicadores em uma mesma estrutura analítica, torna-se possível observar relações entre desempenho, fluxo escolar, atraso escolar e desempenho em avaliações externas, contribuindo para uma leitura mais ampla da Educação Básica brasileira. Dessa forma, o trabalho busca demonstrar como técnicas computacionais podem auxiliar na transformação de dados públicos dispersos em informações organizadas, acessíveis e úteis para análise.

1.1 Motivação

A motivação para o desenvolvimento deste trabalho surgiu da percepção de que, embora o Brasil disponha de uma quantidade significativa de dados educacionais públicos, esses dados nem sempre são facilmente compreendidos ou explorados de maneira integrada. Muitas vezes, os arquivos disponibilizados exigem tratamento prévio, conhecimento técnico e organização adequada para que possam ser utilizados em análises comparativas. Essa necessidade de preparação é coerente com Loh (2014), que ressalta que a quantidade de dados não é suficiente para uma análise de qualidade: os dados precisam apresentar qualidade e estar organizados em formato adequado ao processo analítico.

No campo educacional, IDEB, SAEB, Rendimento Escolar e Distorção Idade-Série permitem acompanhar dimensões distintas da Educação Básica, como desempenho em

avaliações externas, fluxo escolar e distorção idade-série (INEP, 2024; INEP, 2025a; INEP, 2025b; INEP, 2026). Quando analisados separadamente, esses indicadores oferecem recortes específicos da realidade educacional; sua integração, no escopo deste trabalho, permite colocá-los em uma mesma estrutura analítica e observar conjuntamente desempenho, aprovação, reprovação, abandono e atraso escolar. A inclusão da PND 2025 como base complementar também possibilita observar informações relacionadas ao desempenho de participantes em áreas de formação docente (Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2025b), acrescentando uma dimensão recente ao conjunto de análises realizadas.

Estudos anteriores já apontam a importância do uso de técnicas computacionais no tratamento de dados educacionais. Soares et al. (2021) evidenciam o potencial das bases do INEP para pesquisas relacionadas à mineração e análise de dados educacionais. Ilha e Moreira Junior (2021) demonstram a relevância da construção de um Data Warehouse para organização de indicadores educacionais, enquanto Wanderley (2021) destaca o uso de Business Intelligence na visualização de informações da Educação Básica por meio de dashboards.

Apesar dessas contribuições, ainda existem desafios relacionados à integração de múltiplas bases públicas, à padronização de dados históricos e à construção de modelos analíticos que permitam analisar diferentes dimensões da Educação Básica em conjunto. Nesse sentido, este trabalho parte da necessidade de investigar como a Engenharia de Dados e o Business Intelligence podem contribuir para organizar, integrar e interpretar indicadores educacionais brasileiros de maneira mais acessível e estruturada.

1.2 Objetivos e Desafios da Pesquisa

O principal desafio desta pesquisa está na complexidade de trabalhar com diferentes bases públicas educacionais, que apresentam formatos, estruturas, períodos e categorias variadas. A integração dessas informações exige processos de extração, limpeza, transformação, padronização, validação e modelagem, de modo que os dados possam ser analisados de forma conjunta e coerente. A questão que orienta o trabalho é: como uma arquitetura reprodutível de Engenharia de Dados pode integrar bases educacionais heterogêneas do INEP e disponibilizá-las de forma consistente para análise no Power BI?

Dessa forma, o objetivo geral deste trabalho é desenvolver e avaliar um pipeline reprodutível de Engenharia de Dados, integrado a uma solução de Business Intelligence, para organizar, validar e disponibilizar indicadores educacionais brasileiros do INEP no período de 2007 a 2023, com análise complementar da PND 2025.

Para alcançar esse objetivo geral, foram definidos os seguintes objetivos específicos:

a) investigar as características das bases públicas educacionais disponibilizadas pelo

INEP, considerando IDEB, SAEB, Rendimento Escolar, Taxa de Distorção Idade-Série e PND 2025;

b) analisar os desafios de integração, padronização e tratamento presentes nas bases educacionais selecionadas;

c) automatizar a aquisição dos insumos oficiais e implementar em Python os processos de ingestão, transformação e carga organizados nas camadas Raw, Bronze, Silver e Gold;

d) padronizar os resultados históricos no nível de Unidade Federativa, priorizando agregados oficiais de UF quando disponíveis e tratando de forma documentada fontes publicadas em granularidades distintas;

e) documentar a origem dos arquivos, sua integridade e a linhagem das transformações para permitir a reprodução do processamento;

f) organizar os indicadores educacionais em um modelo dimensional composto por tabelas fato e dimensão e validar sua integridade;

g) incorporar a PND 2025 como base complementar, utilizando informações de notas, acertos, área de formação e código do município de aplicação da prova;

h) avaliar como dashboards interativos desenvolvidos no Power BI podem favorecer a visualização e interpretação dos indicadores educacionais.

Com isso, este trabalho não se limita à construção de uma solução técnica, mas busca compreender de que forma a integração de dados educacionais pode contribuir para a análise da Educação Básica brasileira. A partir da organização das bases e da criação de visualizações interativas, pretende-se evidenciar possibilidades de leitura dos indicadores públicos, ampliando a compreensão sobre desempenho, fluxo escolar, distorção idade-série e informações complementares da PND 2025.

1.3 Contribuições

As principais contribuições deste trabalho consistem em:

a) integração de diferentes bases públicas educacionais disponibilizadas pelo INEP, permitindo a análise conjunta de indicadores que, originalmente, encontram-se distribuídos em arquivos e estruturas distintas;

b) organização dos indicadores educacionais em uma estrutura dimensional composta por tabelas fato e dimensão, favorecendo consultas e análises históricas;

c) aplicação de processos de ETL para tratamento, padronização e consolidação de dados educacionais referentes ao período de 2007 a 2023;

d) padronização dos resultados históricos em nível de Unidade Federativa, preservando as diferenças de granularidade entre as fontes e priorizando agregados oficiais de UF quando disponíveis;

e) possibilidade de realização de análises comparativas entre IDEB, SAEB, Rendimento Escolar e Taxa de Distorção Idade-Série;

f) incorporação da PND 2025 como análise complementar, com classificação dos padrões de desempenho a partir da nota objetiva;

g) apresentação dos indicadores por meio de dashboards interativos no Power BI, favorecendo a interpretação visual dos dados e a identificação de padrões, tendências e relações entre os indicadores educacionais;

h) disponibilização de manifesto, hashes SHA-256, aquisição automatizada dos insumos oficiais, validações automatizadas e notebooks demonstrativos que tornam explícitos os critérios de tratamento por indicador.

1.4 Organização do trabalho

Este trabalho está organizado em seis capítulos. O primeiro capítulo apresenta a introdução, a motivação, os objetivos, os desafios da pesquisa e as contribuições do trabalho. O segundo capítulo aborda os conceitos teóricos relacionados à Engenharia de Dados, ETL, Data Warehouse, modelagem dimensional, Business Intelligence e indicadores educacionais brasileiros. O terceiro capítulo apresenta estudos relacionados ao uso de dados e tecnologias analíticas no contexto educacional. O quarto capítulo descreve os procedimentos metodológicos adotados para coleta, tratamento, modelagem e visualização dos dados. O quinto capítulo apresenta os resultados e discussões obtidos a partir dos dashboards desenvolvidos. Por fim, o sexto capítulo apresenta as conclusões, limitações e possibilidades de trabalhos futuros.

Capítulo 2

Fundamentação Teórica

Este capítulo apresenta os principais conceitos relacionados ao desenvolvimento deste trabalho, abordando fundamentos de Engenharia de Dados, processos de ETL, Data Warehouse, modelagem dimensional, Business Intelligence e indicadores educacionais brasileiros. Esses conceitos são necessários para compreender as técnicas utilizadas na construção da solução proposta e a importância da transformação de dados brutos em informações relevantes para análise.

2.1 Engenharia de Dados

Com o crescimento da produção de dados em diferentes setores da sociedade, tornou-se necessário estruturar processos capazes de integrar, transformar e disponibilizar informações para uso analítico. Neste trabalho, a Engenharia de Dados é abordada operacionalmente como o conjunto de práticas empregado na construção desses fluxos, abrangendo ingestão, padronização, tratamento, modelagem e disponibilização dos dados. Em estudo aplicado à UFRN, Carvalho (2025) organiza um pipeline justamente nessas etapas, partindo da coleta e ingestão até a modelagem dimensional, o cálculo de indicadores e a validação dos resultados.

A organização do fluxo não se limita ao armazenamento. A qualidade e a rastreabilidade dos dados também condicionam a confiabilidade das análises. Moreno e Oliveira (2026) discutem dimensões como acurácia, completude, consistência e disponibilidade, enquanto Silva (2025) relaciona a proveniência ao registro da origem, do histórico e das transformações dos dados. Esses aspectos são especialmente relevantes quando diferentes fontes precisam ser combinadas em uma mesma estrutura analítica.

No contexto educacional, a aplicação desses conceitos permite integrar diferentes bases de dados relacionadas ao ensino, possibilitando análises mais amplas sobre indicadores de desempenho, permanência escolar, fluxo educacional e evolução histórica da educação. Essa integração é especialmente importante quando as bases públicas apresentam dife-

renças de formato, período, nível de agregação e nomenclatura das variáveis, exigindo processos de tratamento e padronização antes da análise.

2.2 Processo ETL (Extract, Transform, Load)

Um dos principais processos utilizados na Engenharia de Dados é conhecido como ETL, sigla referente às etapas de extração (*Extract*), transformação (*Transform*) e carga (*Load*). Esse processo tem como objetivo coletar dados de diferentes fontes, realizar os tratamentos necessários e disponibilizar as informações em uma estrutura adequada para análise, conforme Kimball e Ross (2013).

A etapa de extração corresponde ao processo inicial de obtenção dos dados. Nessa fase, as informações podem ser coletadas de diferentes origens, como bancos de dados, arquivos estruturados, APIs e sistemas externos. Um dos desafios dessa etapa está relacionado à diversidade dos formatos encontrados, exigindo mecanismos capazes de interpretar diferentes estruturas de armazenamento, conforme Kimball e Ross (2013).

Após a extração ocorre a etapa de transformação, considerada uma das fases mais importantes do processo. Nesse momento são realizadas atividades de limpeza e preparação dos dados, incluindo remoção de registros inconsistentes, tratamento de valores ausentes, padronização de formatos, criação de novas variáveis e integração entre diferentes bases, conforme Kimball e Ross (2013).

A etapa de transformação também pode envolver processos de alteração da estrutura dos dados, como a conversão de tabelas em formato amplo para formatos mais adequados à análise, padronização de códigos, criação de colunas derivadas, agrupamentos e consolidação de diferentes arquivos históricos. Em bases educacionais públicas, essas etapas são necessárias porque os dados podem ser disponibilizados em arquivos separados por ano, etapa de ensino, rede, Unidade Federativa, município ou escola.

A última etapa corresponde à disponibilização dos dados tratados em uma estrutura de destino, como um Data Warehouse, um modelo dimensional ou outra base consolidada. No contexto educacional, Ilha e Moreira Junior (2021) descrevem a importação de indicadores do INEP para um repositório estruturado em Data Warehouse e sua posterior exploração por recursos de Business Intelligence e dashboards.

No desenvolvimento deste trabalho, os conceitos de ETL fundamentam a integração das bases educacionais selecionadas. A implementação específica das etapas de auditoria, ingestão, transformação e validação é apresentada na metodologia.

2.3 Arquitetura em camadas e reprodutibilidade

Arquiteturas de dados em camadas permitem separar estágios de ingestão, tratamento e consumo analítico, estabelecendo responsabilidades distintas ao longo do fluxo de pro-

cessamento. Em estudo aplicado à gestão de dados da UFRN, Carvalho (2025) descreve uma organização em camadas Bronze, Silver e Gold, na qual os dados são inicialmente preservados em formato próximo ao original, passam posteriormente por limpeza, padronização e validação e, por fim, são refinados e modelados para consumo analítico.

A qualidade dos dados constitui outro aspecto relevante para a confiabilidade das análises. Moreno e Oliveira (2026) discutem dimensões como acurácia, completude, consistência e disponibilidade e destacam que a existência de grande volume de dados, isoladamente, não assegura maior valor analítico. Em seu estudo, os autores identificaram associações positivas entre a percepção dessas dimensões de qualidade e a confiança nos processos decisórios. Dessa forma, procedimentos de validação, padronização e integração são importantes para reduzir inconsistências antes que os dados sejam utilizados em análises.

A reprodutibilidade computacional depende não apenas da apresentação dos resultados finais, mas também da documentação dos dados de entrada, do código executado e das dependências necessárias ao ambiente de processamento. Ao investigar a reprodução de pesquisas apoiadas por infraestrutura computacional, Ferreira (2024) identificou dificuldades associadas à ausência de referências diretas aos dados utilizados, às versões do código-fonte e às dependências de software. A autora destaca, assim, a importância de práticas e ferramentas que documentem e preservem os artefatos de pesquisa ao longo do tempo.

A rastreabilidade também se relaciona ao conceito de proveniência de dados. Silva (2025) caracteriza a proveniência como o registro da origem, do histórico e das transformações dos dados, relacionando-a à autenticidade, à confiabilidade e à rastreabilidade das informações. O registro desses elementos permite compreender como um dado foi produzido ou modificado e favorece sua avaliação e reutilização em diferentes contextos.

No presente trabalho, esses princípios são operacionalizados por meio das camadas Raw, Bronze, Silver e Gold. A Raw preserva cópias organizadas dos insumos oficiais; a Bronze realiza a leitura inicial e conserva metadados técnicos; a Silver aplica recortes, harmonização e regras de qualidade; e a Gold materializa fatos e dimensões destinados ao consumo analítico. O projeto mantém ainda inventário dos arquivos Raw, endereços das fontes oficiais, hashes SHA-256, documentação de linhagem e validadores executáveis. O hash não comprova a correção metodológica de uma fonte, mas permite verificar se o arquivo utilizado em uma reprodução é idêntico ao inventariado. Essa organização também evita que o Power BI precise reinterpretar os arquivos de origem, pois a ferramenta consome exclusivamente a camada Gold.

2.4 Data Warehouse e Modelagem Dimensional

O Data Warehouse é utilizado para organizar e integrar dados destinados a consultas e análises. No contexto educacional, Ilha e Moreira Junior (2021) empregam essa tecnologia para reunir indicadores disponibilizados pelo INEP em um repositório analítico e viabilizar sua exploração por ferramentas de Business Intelligence. Essa finalidade é compatível com a modelagem dimensional voltada a ambientes analíticos descrita por Kimball e Ross (2013).

Uma das abordagens utilizadas na construção de ambientes analíticos é a modelagem dimensional. Segundo Kimball e Ross (2013), essa abordagem organiza os dados em estruturas compostas por tabelas fato e tabelas dimensão, favorecendo consultas e análises.

As tabelas fato armazenam os eventos ou indicadores que serão analisados, geralmente contendo valores numéricos e métricas. Já as tabelas dimensão representam características utilizadas para contextualizar essas informações, como tempo, localização, etapa de ensino, área de formação ou outras categorias de análise, conforme Kimball e Ross (2013).

Entre os modelos dimensionais mais utilizados encontra-se o esquema estrela (*Star Schema*), no qual uma ou mais tabelas fato se relacionam diretamente com dimensões compartilhadas. Kimball e Ross (2013) apresentam essa estrutura como uma organização característica da modelagem dimensional voltada a ambientes analíticos.

Neste trabalho, esses conceitos fundamentam a modelagem dimensional implementada na camada Gold. A estrutura específica de fatos, dimensões e relacionamentos é apresentada na Seção 4.5, onde são descritos o grão analítico e as decisões de relacionamento adotadas.

2.5 Business Intelligence e Visualização de Dados

Business Intelligence (BI) é tratado por Loh (2014) como um processo que envolve métodos, técnicas, tecnologias, pessoas, informações, fontes, métricas e ferramentas, com o propósito de apoiar a compreensão de problemas e a tomada de decisão fundamentada em dados.

Essa perspectiva não restringe BI à construção de dashboards ou relatórios. Loh (2014) diferencia o processo de BI da simples geração de visualizações e destaca que a preparação e a qualidade dos dados condicionam a qualidade das análises, reforçando a necessidade de organizar os dados em formato adequado antes de sua exploração analítica.

A visualização constitui uma das formas de disponibilizar os resultados desse processo. Em aplicação voltada à Educação Básica, Wanderley (2021) desenvolve uma solução de BI baseada em painéis interativos para apresentar indicadores educacionais e apoiar a avaliação das informações por gestores.

Entre as ferramentas disponíveis atualmente destaca-se o Power BI, plataforma que

possibilita a conexão com diferentes fontes de dados, aplicação de processos de transformação, criação de modelos relacionais e desenvolvimento de dashboards analíticos (Microsoft, 2025).

A utilização de BI na área educacional possibilita analisar grandes conjuntos de dados relacionados ao desempenho dos estudantes, contribuindo para identificar padrões, acompanhar a evolução de indicadores e comunicar resultados de forma mais clara. No caso deste trabalho, esses conceitos fundamentam o uso do Power BI como camada de consumo analítico e visualização; sua implementação é detalhada na metodologia.

2.6 Indicadores Educacionais Brasileiros

A avaliação e o acompanhamento da qualidade educacional dependem da utilização de indicadores capazes de representar diferentes aspectos do processo de ensino. No Brasil, o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) disponibiliza diferentes bases de dados relacionadas à Educação Básica (INEP, 2024).

O Índice de Desenvolvimento da Educação Básica (IDEB) é um indicador utilizado para acompanhar a qualidade da educação brasileira, combinando informações relacionadas ao desempenho dos estudantes em avaliações externas e ao fluxo escolar (INEP, 2024). Por reunir aspectos de aprendizagem e rendimento, o IDEB é frequentemente utilizado para observar a evolução da educação ao longo do tempo e comparar resultados entre diferentes unidades territoriais.

O Sistema de Avaliação da Educação Básica (SAEB) é composto por avaliações aplicadas aos estudantes com o objetivo de medir competências e habilidades, principalmente nas áreas de Língua Portuguesa e Matemática (INEP, 2025a). No contexto deste trabalho, os dados do SAEB foram utilizados para analisar a proficiência média dos estudantes nessas áreas, considerando sua relação com outros indicadores, como IDEB e taxas de rendimento escolar.

Além dos indicadores de desempenho, as taxas de rendimento escolar apresentam informações relacionadas ao fluxo dos estudantes, incluindo aprovação, reprovação e abandono escolar. Esses dados possibilitam compreender aspectos relacionados à permanência e progressão dos alunos durante sua trajetória escolar (INEP, 2025b). A análise dessas taxas permite observar se os estudantes estão avançando nas etapas escolares ou se há maiores níveis de retenção e abandono.

Outro indicador relevante é a Taxa de Distorção Idade-Série (TDI), que representa a proporção de estudantes que se encontram em atraso escolar em relação à idade considerada adequada para determinada etapa de ensino (INEP, 2026). Esse indicador é importante porque ajuda a compreender desigualdades na trajetória escolar, evidenciando situações em que os estudantes permanecem em séries incompatíveis com sua idade.

Além dos indicadores históricos da Educação Básica, este trabalho também utilizou a

Prova Nacional Docente (PND) 2025 como base complementar. A PND foi considerada por apresentar informações relacionadas ao desempenho de participantes em diferentes áreas de formação docente, como Matemática, Pedagogia, Letras, História, Geografia, Ciências Biológicas, entre outras. Para sua utilização, foram considerados dados como área da prova, Unidade Federativa de aplicação, código do município de aplicação, nota objetiva, nota discursiva, nota geral e quantidade de acertos. As variáveis territoriais da PND referem-se ao local de aplicação da prova, não à residência do participante.

A PND 2025 não foi tratada como série histórica, pois corresponde a uma base específica de 2025. Sua utilização ocorreu de forma complementar aos indicadores de 2007 a 2023, permitindo ampliar a análise por meio de informações recentes relacionadas à formação docente. Dessa forma, enquanto IDEB, SAEB, Rendimento Escolar e TDI possibilitam observar a evolução histórica da Educação Básica, a PND contribui com uma perspectiva adicional sobre o desempenho dos participantes em áreas relacionadas à docência.

A integração desses diferentes indicadores possibilita uma análise mais abrangente sobre a educação brasileira, permitindo observar relações entre desempenho, fluxo escolar, trajetória dos estudantes, atraso escolar e informações complementares sobre desempenho em áreas de formação docente. Essa integração não tem como objetivo estabelecer relações causais diretas entre os indicadores, mas favorecer uma leitura mais ampla e organizada dos dados públicos educacionais.

Capítulo 3

Estado da Arte

Este capítulo apresenta trabalhos correlatos ao tema desta pesquisa, com foco em estudos que utilizam bases educacionais públicas, técnicas de Engenharia de Dados, Data Warehouse, Business Intelligence e visualização de dados aplicadas ao contexto educacional. A seleção dos trabalhos considerou pesquisas que se aproximam da proposta deste estudo, especialmente aquelas relacionadas ao uso de dados disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP), à organização de indicadores educacionais e ao desenvolvimento de soluções analíticas para apoio à interpretação de informações da Educação Básica.

A análise dos trabalhos correlatos permite compreender como diferentes autores têm utilizado técnicas computacionais para transformar dados educacionais em informações relevantes. Além disso, possibilita identificar contribuições, diferenças de escopo e lacunas existentes, evidenciando de que forma esta pesquisa se diferencia ao propor a integração de diferentes indicadores educacionais brasileiros em uma estrutura dimensional voltada à análise histórica, comparativa e visual.

3.1 Busca por trabalhos correlatos

Foi realizada uma busca exploratória, de natureza não sistemática, com o objetivo de identificar trabalhos representativos relacionados ao uso de dados educacionais, indicadores do INEP, Engenharia de Dados, Business Intelligence e visualização de dados. A busca não teve como finalidade realizar um levantamento exaustivo da literatura, mas selecionar estudos com proximidade temática e metodológica suficiente para contextualizar e comparar a proposta desenvolvida.

A busca foi realizada principalmente por meio do Google Acadêmico, sem delimitação temporal previamente estabelecida. Foram utilizadas, em diferentes combinações, palavras-chave relacionadas a dados educacionais, indicadores educacionais, INEP, Engenharia de Dados, Data Warehouse, Business Intelligence, ETL e visualização de dados.

A seleção considerou a proximidade dos trabalhos com o problema desta pesquisa, especialmente a utilização de bases educacionais, a aplicação de técnicas de tratamento e integração de dados e o desenvolvimento de soluções analíticas ou visualizações. Também foram considerados a disponibilidade do texto completo e o detalhamento metodológico necessário para comparação com a solução proposta.

Como a busca original não foi conduzida como revisão sistemática, não foram registrados quantitativamente todos os resultados retornados, documentos excluídos ou duplicidades encontradas. Por esse motivo, os trabalhos apresentados não representam um levantamento exaustivo da literatura, mas um conjunto de estudos correlatos selecionados para contextualização e comparação da proposta.

Entre os trabalhos identificados, destacam-se os estudos de Soares et al. (2021), Ilha e Moreira Junior (2021), Wanderley (2021) e Martins Filho (2025). Esses trabalhos contribuem para a compreensão do estado da arte relacionado ao uso de dados educacionais e tecnologias analíticas, permitindo observar avanços e diferentes recortes existentes na área.

3.2 Soares et al. (2021)

Soares et al. (2021) realizaram uma revisão sistemática sobre a aplicação de técnicas de mineração de dados utilizando bases da Educação Básica brasileira disponibilizadas pelo INEP. O objetivo do estudo foi identificar pesquisas que utilizam dados educacionais públicos para extração de conhecimento, com atenção a bases como SAEB, IDEB, Censo Escolar e Indicadores Educacionais.

O trabalho apresenta como principal contribuição a sistematização de estudos que utilizam dados educacionais brasileiros, demonstrando o potencial das bases do INEP para pesquisas relacionadas à análise da Educação Básica. Os autores evidenciam que essas bases possuem grande volume de informações e podem apoiar estudos voltados à compreensão do desempenho escolar, do fluxo educacional e de outros aspectos relacionados ao ensino.

Como resultado, a pesquisa aponta que o uso de técnicas computacionais pode contribuir para a extração de conhecimento a partir de dados educacionais. Entretanto, por se tratar de uma revisão sistemática, o trabalho não desenvolve uma solução própria de integração, modelagem ou visualização dos dados. Assim, sua contribuição para esta pesquisa está em demonstrar a relevância das bases públicas do INEP e a necessidade de técnicas adequadas para tratamento e análise dessas informações.

3.3 Ilha e Moreira Junior (2021)

Ilha e Moreira Junior (2021) desenvolveram uma proposta de construção de um Data Warehouse utilizando indicadores educacionais disponibilizados pelo INEP. O estudo teve como objetivo organizar dados educacionais em um ambiente analítico capaz de facilitar consultas e apoiar processos de análise e tomada de decisão.

A pesquisa apresenta relação direta com conceitos de modelagem dimensional, uma vez que propõe a estruturação de dados educacionais em um repositório voltado à análise. O trabalho demonstra que a construção de um Data Warehouse pode contribuir para transformar dados dispersos em informações mais organizadas, acessíveis e úteis para gestores e pesquisadores da área educacional.

Como resultado, os autores indicam que a utilização de Data Warehouse e ferramentas de Business Intelligence pode auxiliar na compreensão de indicadores educacionais e na geração de informações para apoio à gestão. Entretanto, o estudo possui foco principal na construção do ambiente de armazenamento dos dados. A presente pesquisa amplia essa abordagem ao integrar diferentes indicadores educacionais, como IDEB, SAEB, Taxas de Rendimento Escolar, Taxa de Distorção Idade-Série e PND 2025, além de explorar visualizações interativas no Power BI.

3.4 Wanderley (2021)

Wanderley (2021) desenvolveu uma solução baseada em Business Intelligence para avaliação de indicadores de desempenho da Educação Básica no Estado do Acre. O estudo utilizou painéis interativos para representar informações educacionais, buscando facilitar a interpretação dos dados e apoiar processos de tomada de decisão.

O trabalho evidencia a importância do uso de dashboards na área educacional, pois permite transformar dados em representações visuais mais acessíveis. A utilização de ferramentas de BI possibilita a visualização de indicadores de forma dinâmica, favorecendo análises por diferentes dimensões e contribuindo para o acompanhamento da realidade educacional.

Apesar de sua contribuição, o estudo apresenta um recorte regional específico, concentrado no Estado do Acre. Dessa forma, embora se aproxime desta pesquisa pelo uso de Business Intelligence e dashboards, diferencia-se quanto à abrangência e ao conjunto de indicadores analisados. Este trabalho propõe uma abordagem voltada à integração de diferentes bases públicas do INEP, considerando indicadores nacionais e históricos da Educação Básica brasileira no período de 2007 a 2023, além de uma análise complementar da PND 2025.

3.5 Martins Filho (2025)

Martins Filho (2025) investigou a preparação e a visualização de dados de desempenho escolar em uma instituição de Educação Básica, utilizando processo de ETL, Python e dashboards interativos para apoiar a análise histórica dos resultados. O estudo destaca a importância da preparação dos dados e da representação visual das informações para facilitar sua interpretação no contexto educacional.

A principal contribuição do trabalho está na combinação entre tratamento dos dados e dashboards interativos, mostrando como informações históricas de uma escola podem ser organizadas para identificação de padrões e apoio à gestão pedagógica.

Entretanto, o estudo concentra-se em dados de uma única instituição escolar e em um período específico. Assim, sua contribuição para esta pesquisa está em demonstrar a aplicação de ETL e visualização no contexto educacional, enquanto o presente trabalho amplia essa perspectiva ao integrar múltiplas bases públicas do INEP, em escala nacional e com recorte histórico, em um modelo dimensional rastreável e reprodutível.

3.6 Análise comparativa dos trabalhos

A partir dos trabalhos analisados, observa-se que todos apresentam contribuições relevantes para o uso de dados no contexto educacional, embora tenham sido desenvolvidos com objetivos e recortes distintos. Soares et al. (2021) sistematizam pesquisas que utilizam bases do INEP e técnicas de mineração de dados. Ilha e Moreira Junior (2021) abordam a organização de indicadores educacionais em um Data Warehouse. Wanderley (2021) aplica Business Intelligence e painéis interativos em um recorte regional. Martins Filho (2025) combina ETL e visualização interativa para análise de desempenho em um contexto institucional.

Cada estudo, portanto, aproxima-se parcialmente da proposta desta pesquisa por um aspecto específico: uso de bases públicas do INEP, organização em ambiente analítico, aplicação de Business Intelligence ou combinação entre ETL e visualização. As diferenças decorrem principalmente da finalidade, da escala territorial, das bases selecionadas e dos produtos analíticos de cada investigação. Entre os trabalhos analisados, a presente pesquisa reúne esses elementos em uma arquitetura que integra IDEB, SAEB, Taxas de Rendimento Escolar, Taxa de Distorção Idade-Série e PND 2025, com camadas de dados, rastreabilidade dos insumos, validações automatizadas, modelo dimensional e disponibilização analítica no Power BI.

É importante destacar que a PND 2025 não foi utilizada como série histórica, mas como base complementar. Enquanto IDEB, SAEB, Rendimento Escolar e TDI possibilitam acompanhar a evolução de indicadores educacionais entre 2007 e 2023, a PND 2025 permite acrescentar uma leitura recente sobre notas, acertos e áreas de formação do-

cente. Dessa forma, a contribuição técnica do trabalho não se limita à visualização: inclui a organização reprodutível do percurso entre fontes oficiais, camadas de transformação, validações, modelo dimensional e dashboards.

Tabela 1 – Comparação dos trabalhos correlatos.

Trabalho	**Técnica principal**	**Contribuição**	**Diferença em relação a esta pesquisa**
Soares et al. (2021)	Mineração de dados	Evidencia o potencial das bases públicas do INEP para análise educacional	Apresenta uma revisão sistemática da literatura, enquanto esta pesquisa materializa um pipeline e um modelo analítico
Ilha e Moreira Junior (2021)	Data Warehouse e BI	Demonstra a importância da organização dos dados educacionais em ambiente analítico	Prioriza a estruturação de um Data Warehouse educacional, enquanto esta pesquisa reúne também série histórica nacional, rastreabilidade e validações automatizadas
Wanderley (2021)	Business Intelligence	Mostra a aplicação de painéis interativos para análise de indicadores educacionais	Adota recorte regional no Estado do Acre, enquanto esta pesquisa analisa uma série histórica nacional por UF
Martins Filho (2025)	ETL e visualização de dados	Combina preparação de dados e dashboards interativos para análise escolar	Adota recorte institucional em uma escola, enquanto esta pesquisa utiliza múltiplas bases públicas nacionais do INEP
Este trabalho	Engenharia de Dados, ETL, modelagem dimensional e BI	Integra IDEB, SAEB, Rendimento Escolar, Distorção Idade-Série e PND 2025 em uma estrutura analítica única	—

Fonte: Elaborado pelo autor (2026).

3.7 Contribuições do trabalho

No conjunto de estudos analisados, as aproximações com esta pesquisa aparecem em dimensões específicas, como uso de bases do INEP, ETL, Data Warehouse, Business Intelligence e visualização. A contribuição deste trabalho, nesse contexto comparativo, está em reunir esses elementos em uma arquitetura única e reprodutível, aplicada a múltiplos indicadores da Educação Básica em série histórica nacional, com rastreabilidade, validações, modelagem dimensional e disponibilização analítica no Power BI. A PND 2025 permanece como análise complementar e não é tratada como continuidade da série histórica principal.

Capítulo 4

Metodologia

Este capítulo apresenta os procedimentos metodológicos utilizados no desenvolvimento do trabalho. São descritas a classificação da pesquisa, as fontes e os recortes analíticos, a arquitetura do pipeline em Python, as regras de transformação por indicador, os mecanismos de rastreabilidade e validação, a modelagem dimensional da camada Gold e a disponibilização dos dados no Power BI.

4.1 Classificação da pesquisa

Este trabalho caracteriza-se como uma pesquisa aplicada, pois teve como finalidade desenvolver uma solução computacional baseada em Engenharia de Dados e Business Intelligence para organizar, integrar e analisar indicadores educacionais brasileiros (PRODANOV; FREITAS, 2013).

Quanto aos objetivos, a pesquisa classifica-se como descritiva, uma vez que buscou organizar, representar e analisar características relacionadas aos indicadores da Educação Básica brasileira, identificando comportamentos, padrões e variações presentes nos dados ao longo do tempo (GIL, 2002).

Em relação à abordagem, a pesquisa caracteriza-se como quantitativa, pois utilizou bases de dados estruturadas e indicadores numéricos para realização das análises. As informações foram tratadas por meio de técnicas computacionais, permitindo a criação de métricas, comparações históricas, médias, proporções e representações gráficas (PRODANOV; FREITAS, 2013).

Quanto aos procedimentos técnicos, caracteriza-se como pesquisa documental, pois utiliza dados secundários disponibilizados por instituição oficial, sem intervenção direta sobre o ambiente analisado (GIL, 2002). O desenvolvimento inclui ainda a construção de um artefato computacional, composto pelo pipeline de dados, modelo dimensional, medidas semânticas e dashboards.

4.2 Fontes e coleta dos dados

Foram utilizadas bases públicas disponibilizadas pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP): IDEB, SAEB, Taxas de Rendimento Escolar, Taxa de Distorção Idade-Série (TDI) e Prova Nacional Docente (PND) 2025.

A análise histórica compreende o período de 2007 a 2023 para IDEB, SAEB, Rendimento Escolar e TDI, com foco na rede pública e nos Anos Iniciais e Anos Finais do Ensino Fundamental. O Ensino Médio não integra o recorte final. A PND é tratada separadamente, apenas para 2025, e não compõe a série histórica principal.

Os links oficiais do INEP constituem a referência institucional e a fonte primária dos dados. Os arquivos armazenados localmente na camada Raw correspondem aos materiais obtidos dessas fontes e são identificados em manifesto por caminho local, finalidade e hash SHA-256. O inventário utilizado no projeto contém 54 arquivos e pode ser verificado pelo comando `python scripts/gerar_manifesto_raw.py -check`. A cópia organizada da Raw disponibilizada fora do repositório constitui apenas uma conveniência de reprodução e não substitui as fontes oficiais.

A aquisição é automatizada pelo script `scripts/baixar_raw.py`, que identifica os links nas páginas oficiais, seleciona as edições e os arquivos previstos no manifesto, extrai os membros necessários dos pacotes e aplica os nomes locais em `data/raw`. Os pacotes e candidatos temporários são removidos ao final do processamento. Para o conjunto de fontes coberto nesta versão do projeto, a preparação dos insumos não exige seleção, extração ou renomeação manual pelo usuário.

4.3 Arquitetura e processo de ingestão

A solução foi organizada em quatro camadas de dados, seguidas pela camada de consumo analítico:

$$\texttt{RAW} \rightarrow \texttt{BRONZE} \rightarrow \texttt{SILVER} \rightarrow \texttt{GOLD} \rightarrow \texttt{POWER BI}$$

A Figura 1 apresenta o percurso completo, incluindo a etapa anterior à Raw. Neste trabalho, aquisição designa a obtenção dos arquivos nas fontes oficiais e sua organização na Raw; ingestão designa a leitura e a estruturação desses insumos na Bronze.

A Raw preserva os insumos oficiais organizados localmente. A Bronze realiza a ingestão com padronização técnica mínima e preservação de metadados. A Silver aplica o recorte analítico, harmonização de categorias, seleção das observações e validações de correspondência com a Bronze. A Gold materializa as tabelas fato e dimensão consumidas pelo Power BI.

Os arquivos de origem apresentam formatos heterogêneos, incluindo `.xls`, `.xlsx`, `.xlsb`, `.csv` e `.txt`. A leitura e o processamento são executados por scripts Python. O



Figura 1 – Percurso dos dados, da aquisição nas fontes oficiais ao consumo analítico.

Fonte: Elaborado pelo autor a partir da implementação do projeto (2026).

orquestrador `src/pipeline.py` organiza as etapas de Bronze, Silver, Gold e validação global e disponibiliza, entre outros, os comandos `bronze`, `silver`, `gold`, `validate-gold` e `full`, além do modo `-dry-run` para inspeção da sequência sem execução analítica.

A nomenclatura local da Raw é aplicada automaticamente a partir do manifesto, preservando a identificação temporal das edições sem alterar seus valores. O IDEB utiliza um único nome local estável, `divulgacao_regioes_ufs_ideb.xlsx`, enquanto os anos disponíveis são identificados pelo conteúdo do workbook. Essa distinção permite atualizar a edição física da fonte sem modificar os caminhos esperados pelo pipeline.

4.4 Transformação, linhagem e validação

As transformações foram implementadas em Python de acordo com as particularidades de cada fonte. Entre os procedimentos aplicados estão identificação de cabeçalhos técnicos, padronização de tipos, normalização de Unidades Federativas, tratamento de valores ausentes, harmonização de categorias, seleção de rede e etapa, transformação entre formatos amplo e longo quando necessária e validação do grão analítico.

A rastreabilidade é preservada ao longo do pipeline. Na Bronze são mantidos metadados técnicos associados à fonte, ao hash, ao nome do arquivo e à aba de origem, ao ano de referência, à posição das linhas e à granularidade preservada, conforme aplicável. Na Silver, os registros analíticos são validados diretamente contra suas células de origem por arquivo, linha e coluna; no IDEB e no SAEB, também são consideradas aba e granularidade quando pertinentes. Essa estratégia permite relacionar um valor analítico à observação de origem utilizada em sua construção.

As informações de rede são selecionadas segundo a semântica de cada fonte, sem cal-

cular indiscriminadamente média entre redes federal, estadual e municipal. Rendimento e TDI utilizam o agregado público oficial; o IDEB seleciona a categoria pública disponibilizada no arquivo; e o SAEB aplica regras específicas por edição. A rede privada é excluída. No SAEB de 2007 e 2009, a categoria histórica disponível corresponde a `Total - Estadual e Municipal`, particularidade considerada como limitação de comparabilidade da série.

As validações abrangem esquema, domínios, quantidade de registros, unicidade no grão, cobertura temporal e territorial, correspondência entre camadas, chaves órfãs e consistência dos relacionamentos. Na Gold, o validador global verifica também a integridade referencial e a coerência entre município e UF na PND.

4.4.1 Desafios de harmonização histórica

Um dos principais desafios de transformação não foi apenas converter formatos de arquivo, mas reconhecer que uma mesma informação passou a ser representada de maneiras diferentes entre indicadores e edições. As fontes variam quanto à posição e ao nome das colunas, quantidade de linhas de cabeçalho, uso de códigos ou categorias textuais, presença de Brasil e regiões junto às UFs, granularidade de publicação e representação de valores ausentes. Por esse motivo, o pipeline não aplica uma regra genérica baseada apenas na aparência do arquivo. Cada configuração foi definida após auditoria da respectiva fonte e foi materializada explicitamente nos transformadores.

Na Bronze, colunas de planilhas com cabeçalhos complexos recebem nomes técnicos neutros, como `col_001`, `col_002` e assim sucessivamente. Esses nomes representam a posição física preservada e não atribuem significado novo ao dado. Na Silver, a posição é associada ao conceito identificado na auditoria. Por exemplo, a taxa de aprovação dos Anos Iniciais do Rendimento encontra-se em `col_015` em 2007, em `col_014` entre 2008 e 2010 e em `col_006` entre 2011 e 2015. A correspondência é registrada em `COLUNA_ORIGEM`, permitindo retornar à célula utilizada.

Também foi necessária a passagem do formato amplo para o formato longo. Nas fontes de Rendimento, TDI, IDEB e SAEB, diferentes anos, etapas, indicadores ou disciplinas aparecem distribuídos em colunas. Na Silver, essas dimensões tornam-se valores explícitos em campos canônicos, como `ANO`, `ETAPA`, `INDICADOR` e `DISCIPLINA`. Por essa razão, a quantidade de linhas da Bronze e da Silver não deve ser interpretada como simples contagem de registros removidos: uma linha de origem pode produzir várias observações analíticas.

A Tabela 2 resume as diferenças que determinaram as regras de transformação. O mapeamento completo dos campos encontra-se no Apêndice A; as categorias e códigos harmonizados, no Apêndice B; os critérios de inclusão e exclusão, no Apêndice C; e os controles de qualidade e rastreabilidade, no Apêndice D.

Tabela 2 – Síntese dos desafios e decisões de harmonização por indicador e período.

Indicador	**Período**	**Diferença encontrada**	**Decisão implementada**	**Saída canônica**
Rendimento	2007–2023	Cinco configurações de posição; presença ou ausência de região; UF por sigla ou nome; rede como `Publico` ou `Publica`; três indicadores distribuídos em colunas.	Seleção de localização total e agregado público oficial; mapeamento explícito das colunas por período; UF convertida para sigla; taxas convertidas para número e arredondadas a uma casa decimal; estrutura ampla convertida para longa.	`ANO`, `UF`, `ETAPA`, `REDE`, `INDICADOR`, `VALOR`.
TDI	2007–2023	Cinco configurações de posição; mudanças na representação da UF e da rede; Brasil e regiões presentes junto às UFs nas edições recentes.	Seleção de localização total e agregado `Publico/Publica`; exclusão de Brasil e regiões do grão analítico; mapeamento explícito das duas etapas; valores entre 0 e 100, com uma casa decimal.	`ANO`, `UF`, `ETAPA`, `REDE`, `TDI`.
IDEB	2007–2023	Workbook com abas de Anos Iniciais, Anos Finais e Ensino Médio; nomes completos e abreviados de UFs; anos identificados por variáveis técnicas; arquivo físico também contém edições fora do recorte.	Uso das abas de Anos Iniciais e Finais; seleção de `Publica (4)`; localização de cada edição por `VL_OBSERVADO_AAAA`; normalização explícita das UFs; seleção deliberada das nove edições de 2007 a 2023.	`ANO`, `UF`, `ETAPA`, `REDE`, `IDEB`.
SAEB	2007–2023	Categorias textuais em 2007/2009; códigos em 2011; cabeçalhos hierárquicos em 2013/2015; nomes técnicos nas edições recentes; duas granularidades preservadas em 2023.	Regras específicas por edição; harmonização de séries/anos escolares em duas etapas e de disciplinas em `LP`/`MT`; tratamento documentado do zero de 2015; uso do agregado oficial de UF em 2023.	`ANO`, `UF`, `ETAPA`, `REDE`, `DISCIPLINA`, `PROFICIENCIA`.
PND	2025	Microdados com 26 campos, códigos categóricos, marcadores `NA`, ausência de identificador individual e registros de presença sem resultados completos.	Mapeamento da posição física para os nomes do dicionário; população definida por `TP_PRES=555` e cinco resultados completos; preservação de notas negativas publicadas; área derivada de `CO_GRUPO`; linha de origem usada como identificador técnico.	Fato individual com ano, local de prova, área, códigos de aplicação e cinco resultados analíticos.

Fonte: Elaborado pelo autor a partir das auditorias e dos transformadores do projeto (2026).

As escolhas acima distinguem exclusão analítica de perda de informação. Registros, colunas e granularidades que não pertencem ao recorte final permanecem na Raw ou na Bronze. A Silver seleciona a população e as variáveis necessárias à pergunta de pesquisa, enquanto a Gold projeta o conjunto validado para consumo no Power BI. Nenhuma dessas etapas autoriza substituir o agregado oficial por média simples, interpretar marcador de ausência como zero ou expandir automaticamente o período quando a fonte física recebe nova edição.

4.4.2 Tratamento da base IDEB

O IDEB utiliza um único arquivo Raw canônico de divulgação por Regiões e Unidades da Federação. A versão física corrente do arquivo pode conter colunas de edições posteriores, inclusive 2025, mas a Silver e a Gold desta versão selecionam deliberadamente as nove edições de 2007 a 2023: 2007, 2009, 2011, 2013, 2015, 2017, 2019, 2021 e 2023. Assim, a atualização física da fonte não amplia automaticamente o escopo analítico.

A tabela final `FATO_IDEB` contém `ANO`, `UF`, `ETAPA`, `REDE` e `IDEB`. O Ensino Médio é excluído, mantendo apenas Anos Iniciais e Anos Finais da rede pública.

4.4.3 Tratamento da base SAEB

A série final do SAEB utiliza resultados oficiais agregados por Unidade Federativa para as nove edições entre 2007 e 2023. As disciplinas são harmonizadas em Língua Portuguesa e Matemática. Arquivos escolares e microdados permanecem no projeto para auditoria e rastreabilidade, mas não constituem a regra geral de cálculo da fato final.

Uma auditoria específica de 2023 comparou o agregado oficial com reconstruções baseadas em escolas. Como nem a média simples nem a média ponderada por participantes reproduziram os valores oficiais de UF, o projeto preservou o resultado agregado publicado pelo INEP. A `FATO_SAEB` final contém `ANO`, `UF`, `ETAPA`, `REDE`, `DISCIPLINA` e `PROFICIENCIA`.

4.4.4 Tratamento da base de Rendimento Escolar

O Rendimento Escolar utiliza 17 arquivos anuais, de 2007 a 2023, obtidos no item oficial referente a Brasil, regiões e UFs. Os layouts variam entre períodos e são tratados por configurações específicas em Python. A seleção analítica utiliza o agregado público oficial e as etapas Anos Iniciais e Anos Finais.

A tabela `FATO_RENDIMENTO` contém `ANO`, `UF`, `ETAPA`, `REDE`, `INDICADOR` e `VALOR`. Os indicadores `APROVACAO`, `REPROVACAO` e `ABANDONO` compartilham a mesma estrutura factual.

4.4.5 Tratamento da base de Distorção Idade-Série

A TDI também utiliza 17 arquivos anuais, de 2007 a 2023, referentes a Brasil, regiões e UFs. Após a harmonização dos diferentes layouts, a saída analítica é consolidada na `FATO_TDI`, com as colunas `ANO`, `UF`, `ETAPA`, `REDE` e `TDI`.

A TDI permanece na escala de 0 a 100. As medidas temporais calculadas no Power BI não pressupõem que todas as fontes tenham observação em todos os anos; para cada indicador, a variação utiliza o primeiro e o último ano com dado dentro do intervalo selecionado.

4.4.6 Tratamento da base PND 2025

A PND 2025 foi incorporada como análise complementar. O arquivo de microdados possui 1.087.359 registros. A auditoria identificou 759.152 registros com os cinco resultados analíticos completos; 759.140 desses registros também atendem ao critério `TP_PRES = 555` e constituem a população analítica. Permanecem fora 966 registros presentes sem o conjunto completo de resultados e 12 registros com `TP_PRES = 888` apesar de apresentarem resultados completos.

Como os microdados não fornecem um identificador individual, a linha de origem preservada na Silver é utilizada exclusivamente como identificador técnico de rastreabilidade do registro e não constitui identificador do participante.

A Gold preserva `UF_PROVA` e `CO_MUNICIPIO_PROVA`, que representam o local de aplicação da prova e não a residência do participante. Também preserva o código de área `CO_GRUPO`, as notas e resultados analíticos e o campo `PADRAO_DESEMPENHO`. O código municipal é relacionado à `DIM_MUNICIPIO`; a Gold não incorpora nome de município na fato.

A classificação de desempenho é baseada exclusivamente na nota objetiva. A Nota Técnica nº 44/2025/CEI/CGGI/DAES-INEP documenta a transformação da proficiência objetiva para a escala de divulgação de `NT_OBJ`, e a Nota Técnica nº 1/2026/GPP/GAB-INEP estabelece os pontos de corte utilizados na PND por meio do método de Angoff Modificado (Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2025a; Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2026). O projeto aplica:

$$\texttt{NT_OBJ} < 50 \rightarrow \texttt{NAO_PROFICIENTE}$$
$$50 \leq \texttt{NT_OBJ} < 70 \rightarrow \texttt{PADRAO_1}$$
$$\texttt{NT_OBJ} \geq 70 \rightarrow \texttt{PADRAO_2}$$

Os grupos `PADRAO_1` e `PADRAO_2` compõem a medida de proficientes. Essa classificação não representa aprovação ou reprovação e o corte de 50 pontos não deve ser interpretado como 50% de acertos.

4.5 Modelagem dos dados

Após as transformações, a camada Gold materializa cinco tabelas fato e cinco dimensões para consumo analítico. As fatos são `FATO_RENDIMENTO`, `FATO_TDI`, `FATO_IDEB`, `FATO_SAEB` e `FATO_PND`. As dimensões são `DIM_UF`, `DIM_TEMPO`, `DIM_ETAPA`, `DIM_AREA_PND` e `DIM_MUNICIPIO`.

O grão de cada tabela fato foi definido antes de sua materialização. A `FATO_RENDIMENTO` representa uma observação por ano, UF, etapa e indicador; a `FATO_TDI`, uma observação por ano, UF e etapa; a `FATO_IDEB`, uma observação por ano, UF e etapa; a `FATO_SAEB`, uma observação por ano, UF, etapa e disciplina; e a `FATO_PND` mantém granularidade individual para cada registro que atende aos critérios definidos para a população analítica.

Os relacionamentos seguem cardinalidade 1:* e filtro unidirecional da dimensão para a fato. `DIM_UF` relaciona-se com as cinco fatos; `DIM_TEMPO`, também. `DIM_ETAPA` relaciona-se apenas com as quatro fatos históricas. Para a PND, os relacionamentos adicionais utilizam `DIM_AREA_PND` e `DIM_MUNICIPIO`. Não existe relação física direta entre `DIM_UF` e `DIM_MUNICIPIO`, evitando um segundo caminho geográfico até a `FATO_PND`.



Figura 2 – Modelo dimensional atual consumido pelo Power BI.

Fonte: Elaborado pelo autor a partir do modelo Power BI do projeto (2026).

Na Figura 2, a tabela `_MEDIDAS` funciona apenas como contêiner técnico para organizar as medidas DAX no modelo semântico. Ela não constitui uma sexta dimensão nem uma tabela fato analítica.

4.6 Desenvolvimento das métricas analíticas

O modelo semântico possui 27 medidas DAX. As medidas calculam médias, taxas, contagens, proporções, apoio à seleção de anos comparáveis e variações temporais. A Tabela 3 resume os nomes implementados no arquivo `powerbi/medidas_power_bi.dax`.

Tabela 3 – Medidas DAX implementadas no modelo semântico.

Grupo	**Medidas**
Rendimento	`Taxa de Aprovação`; `Taxa de Reprovação`; `Taxa de Abandono`
TDI e IDEB	`TDI Média`; `IDEB Médio`
SAEB	`Proficiência Média SAEB`; `Proficiência Média LP`; `Proficiência Média MT`
PND – médias e contagens	`Participantes PND`; `Nota Objetiva Média`; `Nota Discursiva Média`; `Nota Geral Média`; `Média de Acertos`; `Não Proficientes`; `Padrão 1`; `Padrão 2`; `Proficientes`
PND – percentuais	`% Proficientes`; `% Não Proficientes`; `% Padrão 1`; `% Padrão 2`
Apoio	`Ano de Avaliação Disponível`
Variações	`Variação Aprovação`; `Variação IDEB`; `Variação SAEB Matemática`; `Variação SAEB Português`; `Variação TDI`

Fonte: Elaborado pelo autor a partir do modelo Power BI do projeto (2026).

As taxas de Rendimento e a TDI já são armazenadas na escala de 0 a 100. Os percentuais da PND são razões calculadas dinamicamente e formatadas como percentuais. As medidas de variação representam diferença absoluta entre o último e o primeiro ano com dado no intervalo selecionado. Suas unidades dependem do indicador: pontos de IDEB, pontos percentuais para Aprovação e TDI e pontos de proficiência para SAEB.

4.7 Desenvolvimento dos dashboards

O Power BI consome exclusivamente os arquivos Parquet da Gold. O Power Query é utilizado como camada de conexão com esses arquivos; relacionamentos, medidas DAX e visualizações compõem o modelo semântico e a apresentação analítica.

A solução foi organizada em sete páginas com funções complementares: panorama dos indicadores; comparação por Unidade Federativa; aprendizagem e fluxo escolar; variações no intervalo selecionado; distorção idade-série; resultados da PND 2025; e metodologia e arquitetura do projeto. Essa organização separa a exploração histórica e territorial da documentação técnica do modelo. Os valores, rankings, associações descritivas e demais resultados apresentados em cada página são discutidos no Capítulo 5, evitando duplicar nesta seção a descrição analítica dos painéis.

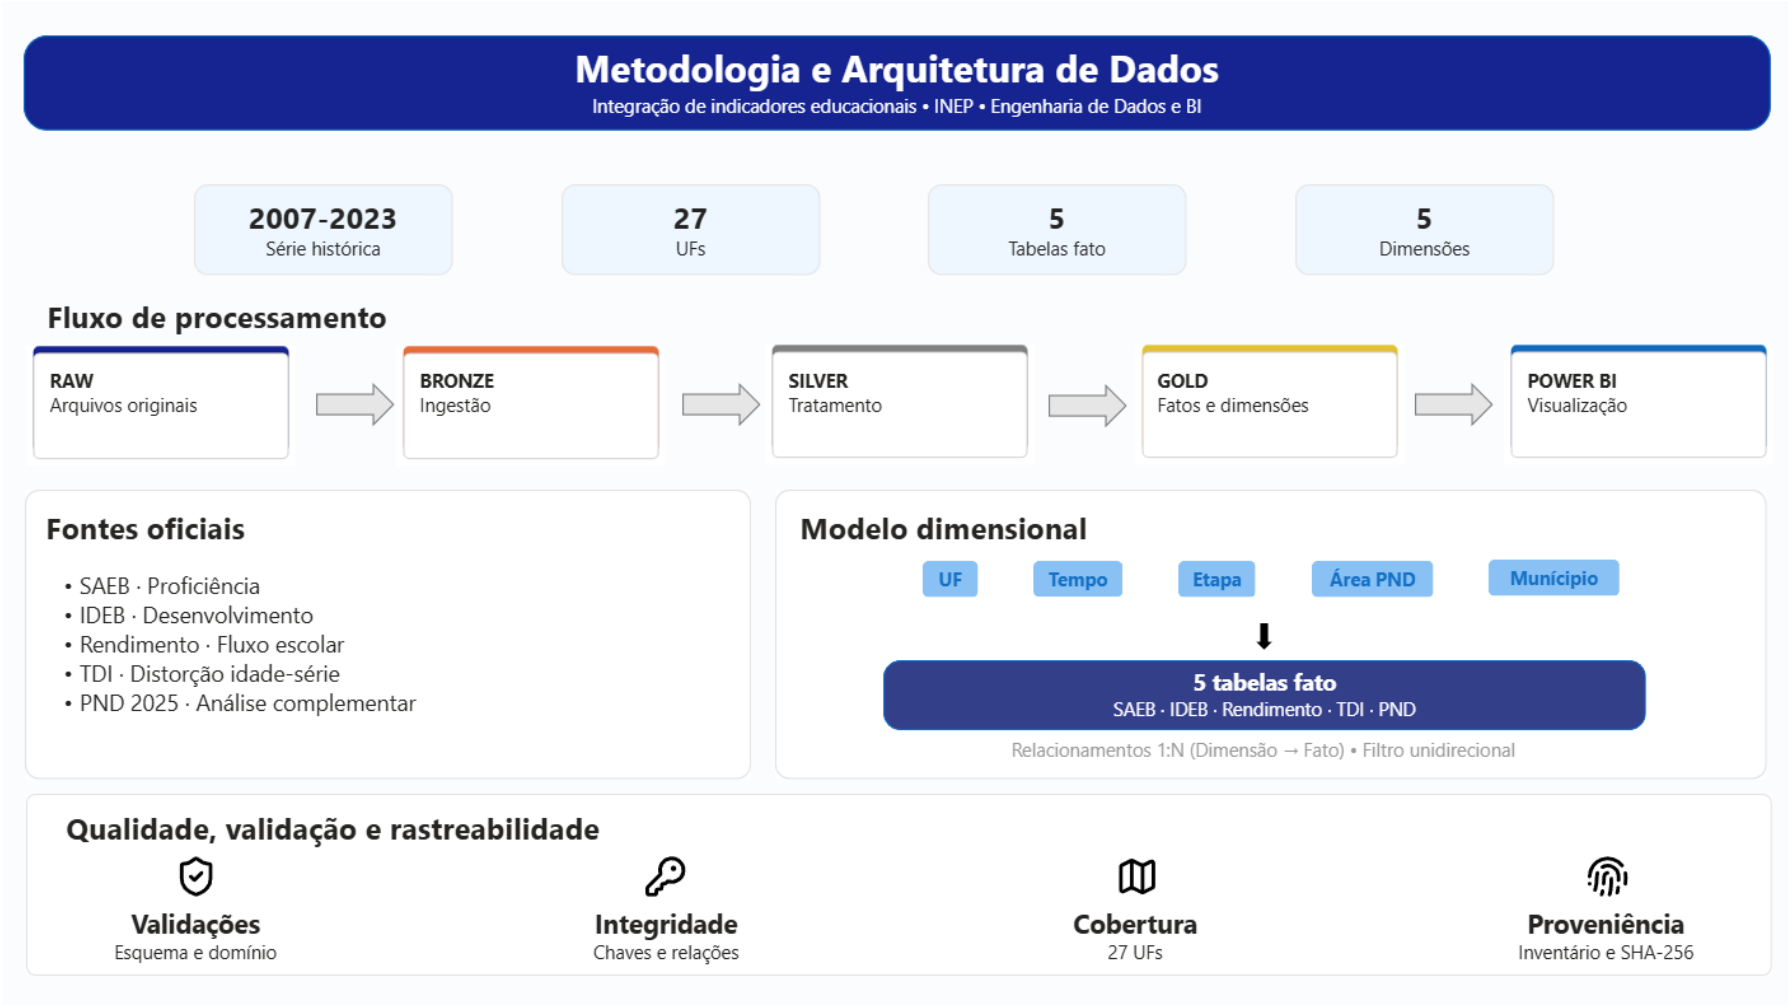


Figura 3 – Página de metodologia e arquitetura do projeto no Power BI.

Fonte: Elaborado pelo autor a partir do dashboard do projeto (2026).

4.8 Notebooks, testes e automação

O repositório possui cinco notebooks demonstrativos, um para cada indicador: Rendimento Escolar, TDI, IDEB, SAEB e PND. Eles apresentam o percurso entre a fonte Raw e a tabela fato Gold correspondente e chamam os scripts oficiais do repositório, sem reimplementar as regras de transformação. Assim, os notebooks funcionam como material demonstrativo e executável da metodologia, enquanto a implementação oficial permanece em `src/`.

Além das validações analíticas, o projeto possui testes automatizados do contrato do repositório e um fluxo de integração contínua para verificações estruturais que não dependem da disponibilidade da Raw. O comando `python src/pipeline.py full -dry-run` valida a sequência de scripts sem executar as transformações, enquanto o manifesto pode ser verificado independentemente por `python scripts/gerar_manifesto_raw.py -check`.

Na aquisição, arquivos com hash diferente são comparados com uma cópia anterior validada. No IDEB, a comparação protege as colunas históricas até 2023 nas três abas lidas pela Bronze; nos demais insumos, protege todas as linhas e campos das abas utilizadas e o conteúdo completo dos arquivos de apoio. Se o conteúdo protegido for igual, a nova versão é instalada e o manifesto é atualizado automaticamente, com backup e registro da comparação. Diferenças históricas, ausência de referência ou falhas de leitura preservam a versão anterior e produzem diagnóstico. O modo `-estrito` exige identidade binária, e essas operações ocorrem antes das transformações, durante as quais a Raw permanece imutável.

4.9 Ferramentas utilizadas

Foram utilizadas Python e as bibliotecas registradas no arquivo `requirements.txt`, incluindo Pandas, NumPy, PyArrow e mecanismos de leitura de planilhas em diferentes formatos. Parquet foi adotado nas camadas derivadas para armazenamento tabular. Também foram utilizados Git para versionamento, notebooks Jupyter como material demonstrativo, Power BI Desktop para o modelo semântico e os dashboards, Power Query para conexão à Gold e DAX para as medidas analíticas.

Essa separação de responsabilidades mantém o processamento reprodutível fora da ferramenta de visualização: Python executa e valida o pipeline; os Parquets constituem a interface analítica; e o Power BI concentra relacionamentos, medidas dependentes do contexto de filtro e visualizações.

4.10 Limitações metodológicas

As fontes apresentam diferenças históricas de formato, layout, nomenclatura, nível de agregação e semântica das categorias. Essas diferenças exigem regras específicas por indicador e por edição e limitam a interpretação de uma série como se todos os anos fossem metodologicamente idênticos.

A análise histórica é harmonizada principalmente no nível de Unidade Federativa, rede pública e Anos Iniciais/Anos Finais. Portanto, os resultados não devem ser generalizados para escolas ou municípios. No SAEB, as categorias de rede de 2007 e 2009 diferem das edições posteriores. IDEB e SAEB possuem periodicidade bienal, enquanto Rendimento e TDI são anuais.

As médias exibidas no Power BI são médias das linhas existentes no contexto de filtro. Quando diversas UFs são agregadas, esses valores não equivalem automaticamente a uma média nacional ponderada por matrículas ou participantes. Essa distinção é especialmente importante ao interpretar os cartões gerais.

A PND corresponde apenas a 2025 e não constitui série temporal. As variáveis territoriais representam o local de aplicação da prova, não residência. A classificação por padrões utiliza `NT_OBJ` e descreve proficiência segundo os pontos de corte adotados; ela não equivale a aprovação ou reprovação.

A reprodução binária exata depende dos arquivos identificados no manifesto e pelos hashes SHA-256. A aquisição automática reduz a intervenção operacional, mas novas edições oficiais podem alterar nomes, layouts ou endereços de download. A aceitação por equivalência requer uma cópia anterior validada e não amplia o período analítico. Sem essa referência, ou quando houver mudança no conteúdo protegido, o processo interrompe a atualização e informa a causa.

Por fim, os dashboards têm finalidade descritiva e exploratória. Associações visuais entre indicadores não permitem estabelecer relações causais nem atribuir mudanças observadas a políticas, condições socioeconômicas ou outros fatores sem desenho de pesquisa específico para inferência causal.

Capítulo 5

Resultados e Discussão

Este capítulo apresenta os resultados técnicos e analíticos obtidos com o pipeline e com os dashboards desenvolvidos no Power BI. Os resultados possuem caráter descritivo e exploratório. Assim, as comparações permitem observar padrões, diferenças territoriais e mudanças temporais, mas não sustentam, por si só, inferências causais.

5.1 Estrutura final do modelo analítico

O primeiro resultado é a consolidação das cinco fontes em um modelo dimensional para consumo analítico. A Gold é composta por cinco tabelas fato e cinco dimensões, validadas antes da conexão com o Power BI. As cardinalidades finais são apresentadas na Tabela 4.

Tabela 4 – Cardinalidades validadas da camada Gold.

Tabela	**Registros**
DIM_UF	27
DIM_TEMPO	18
DIM_ETAPA	2
DIM_AREA_PND	17
DIM_MUNICIPIO	750
FATO_RENDIMENTO	2.754
FATO_TDI	918
FATO_IDEB	486
FATO_SAEB	972
FATO_PND	759.140

Fonte: Validação da camada Gold do projeto (2026).

Foram verificados esquema, domínios, cobertura temporal, unicidade no grão, correspondência entre Silver e Gold, chaves órfãs e coerência entre município e UF. A validação global retornou `MODELO DIMENSIONAL GOLD: OK`. Esse resultado não atesta a qualidade

substantiva das fontes oficiais, mas demonstra que as regras implementadas e os contratos estruturais definidos pelo projeto foram satisfeitos.

5.2 Panorama geral dos indicadores educacionais

A Figura 4 apresenta a visão geral dos indicadores históricos. Na captura sem filtros adicionais, os cartões exibem IDEB médio de 4,5, proficiência média de 223,2 em Matemática e 215,4 em Língua Portuguesa, Taxa de Aprovação de 87,5, Taxa de Reprovação de 9,5, Taxa de Abandono de 3,0 e TDI média de 24,9.

Esses valores devem ser interpretados como médias das linhas presentes no contexto do modelo, e não como médias nacionais ponderadas por matrícula. O principal interesse do painel está na leitura conjunta das trajetórias. O IDEB apresenta trajetória visual predominantemente ascendente entre as edições observadas; as proficiências médias de Matemática e Língua Portuguesa também crescem ao longo de grande parte da série, embora com oscilações nas edições mais recentes. A aprovação cresce no período, enquanto a TDI apresenta redução expressiva ao longo dos anos.

A leitura conjunta indica tendências gerais de melhora em diferentes dimensões do recorte analisado. IDEB e SAEB, porém, são observados em edições bienais, enquanto Rendimento e TDI possuem série anual, o que exige cautela nas comparações temporais.

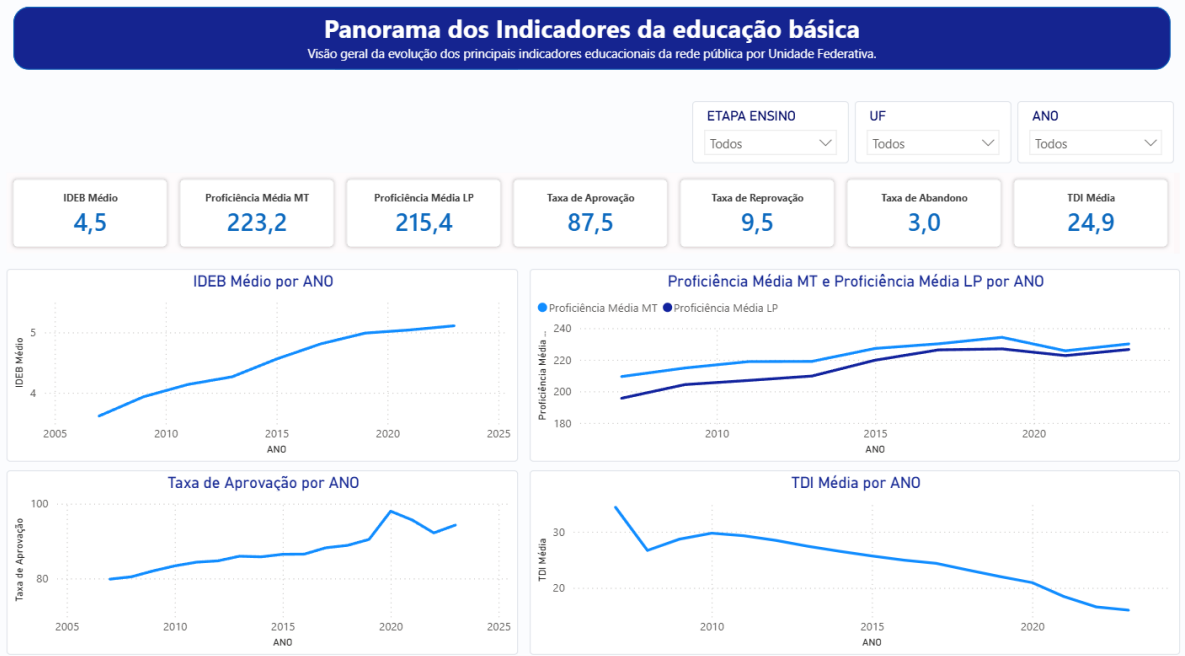


Figura 4 – Panorama dos indicadores da Educação Básica.

Fonte: Elaborado pelo autor a partir do dashboard do projeto (2026).

5.3 Desempenho educacional por Unidade Federativa

A segunda página compara IDEB, SAEB Matemática, TDI e SAEB Língua Portuguesa entre Unidades Federativas em um ano de avaliação disponível. Na captura da Figura 5, o ano selecionado é 2007 e a etapa está em *Todos*.

Nesse recorte, com a etapa configurada como *Todos*, Paraná, Santa Catarina e São Paulo aparecem com valor médio de IDEB de 4,4 entre as barras visíveis. Esse valor corresponde à média das observações presentes no contexto do modelo e não deve ser interpretado como um indicador oficial único publicado para a UF. No SAEB, o Distrito Federal aparece no topo visível tanto em Matemática, com 228,4 pontos, quanto em Língua Portuguesa, com 213,0 pontos. Para TDI, Pará e Alagoas aparecem entre os maiores valores visíveis, com 50,1 e 49,9, respectivamente. Esses exemplos evidenciam que a posição de uma UF depende do indicador analisado e que desempenho, fluxo e atraso escolar não formam uma única dimensão.

A página utiliza rankings separados para evitar transformar indicadores de escalas e significados distintos em uma medida única. Diferenças territoriais de desempenho também podem coexistir com condições sociais e educacionais distintas. Em um recorte específico do SAEB 2023 para o 5º ano de escolas públicas do Rio Grande do Norte, Andrade e Andrade (2026) identificaram diferenças significativas de proficiência entre escolas urbanas e rurais e ressaltaram sua coexistência com características territoriais e socioeconômicas. Embora se trate de outro recorte analítico, o estudo reforça a necessidade de contextualizar a leitura dos rankings.

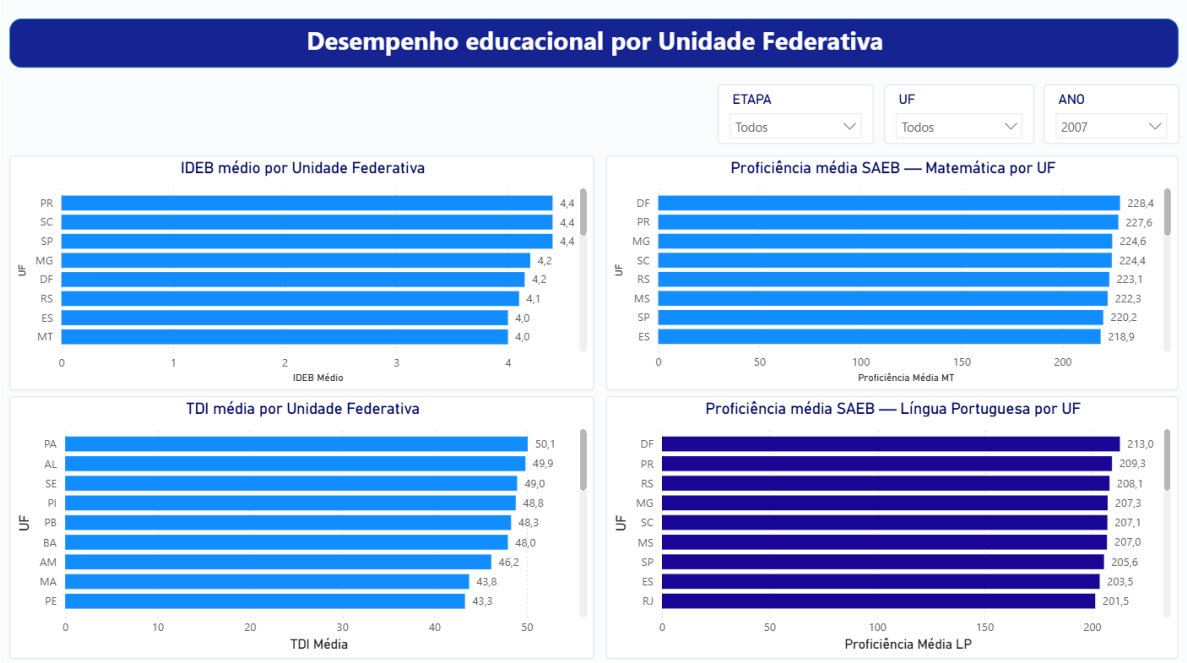


Figura 5 – Desempenho educacional por Unidade Federativa no recorte exibido no dashboard.

Fonte: Elaborado pelo autor a partir do dashboard do projeto (2026).

5.4 Aprendizagem e fluxo escolar

A página de aprendizagem e fluxo escolar combina duas formas de leitura. Na parte superior, são exibidas séries históricas de Aprovação, Reprovação, Abandono e TDI. Na parte inferior, cada ponto representa uma UF no ano selecionado, relacionando Taxa de Aprovação com IDEB e com proficiência média do SAEB.

Na Figura 6, os gráficos históricos mostram aumento da aprovação ao longo do período e redução de TDI, reprovação e abandono em diferentes intensidades. Os gráficos de dispersão, por sua vez, permitem observar associação descritiva entre níveis mais elevados de aprovação e valores mais altos de IDEB ou proficiência em parte das UFs.

O IDEB combina informações de desempenho em avaliações com dados de fluxo escolar em sua composição (INEP, 2024), o que torna esperada alguma proximidade entre aprovação e IDEB. Dias et al. (2026) ressaltam que, embora o IDEB seja um instrumento relevante de diagnóstico e planejamento, sua condição de indicador sintético exige interpretação contextualizada, evitando reduzir a complexidade educacional a uma única medida. A dispersão entre aprovação e proficiência do SAEB, por sua vez, deve ser lida apenas como associação descritiva.

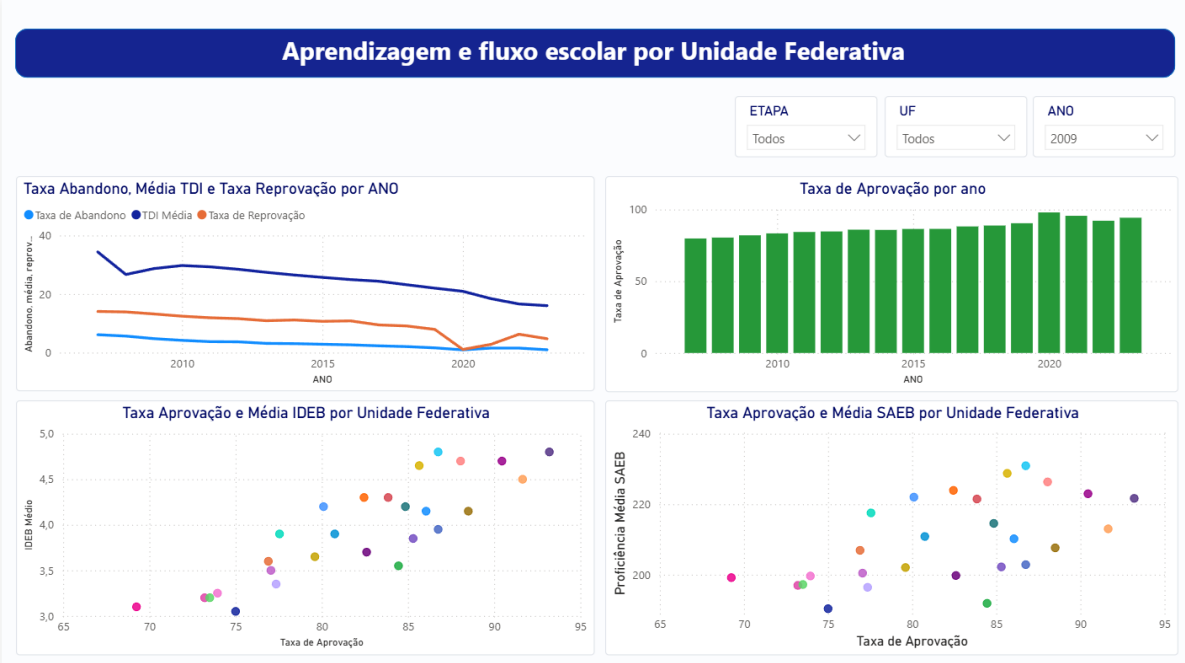


Figura 6 – Aprendizagem e fluxo escolar por Unidade Federativa.

Fonte: Elaborado pelo autor a partir do dashboard do projeto (2026).

5.5 Variação dos indicadores por Unidade Federativa

As medidas de variação comparam o último e o primeiro ano com dado disponível dentro do intervalo selecionado para cada indicador. Isso evita supor observações anuais onde a fonte é bienal. As unidades também diferem: IDEB é expresso em pontos do índice; Aprovação, em pontos percentuais; e SAEB, em pontos de proficiência.

Na Figura 7, o intervalo selecionado é 2007–2023. Entre as barras visíveis, Ceará apresenta a maior variação de IDEB, com 2,6 pontos, e também a maior variação de proficiência em Língua Portuguesa, com 60 pontos, além de 51 pontos em Matemática. Na Taxa de Aprovação, Alagoas aparece com aumento de 27 pontos percentuais. Esses valores descrevem diferença entre extremos observados no período e não uma taxa de crescimento relativa.

As diferenças territoriais reforçam que a evolução não ocorre de forma uniforme entre as UFs.

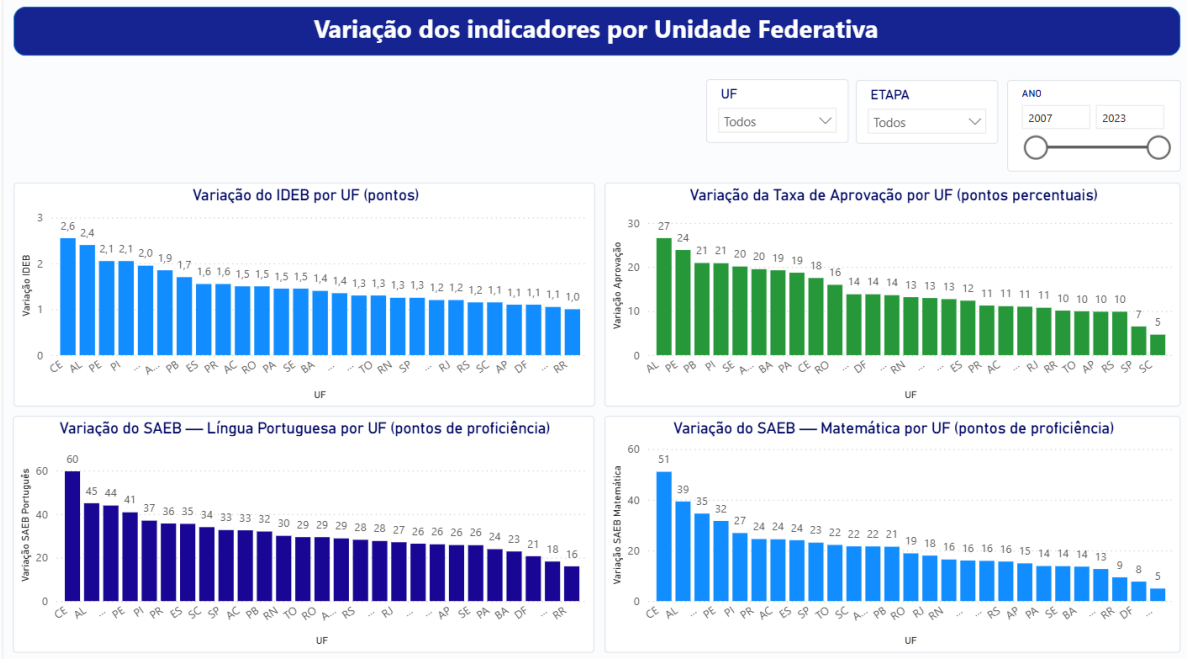


Figura 7 – Variação dos indicadores por Unidade Federativa no intervalo 2007–2023.

Fonte: Elaborado pelo autor a partir do dashboard do projeto (2026).

5.6 Análise da Taxa de Distorção Idade-Série

A Figura 8 apresenta a TDI em quatro perspectivas: evolução anual, média por UF, média por etapa de ensino e variação por UF. No intervalo 2007–2023 mostrado no painel, a TDI média é 24,9 e a Variação TDI é -18,3 pontos percentuais.

A evolução temporal passa de 34,4 no início da série exibida para 16,0 em 2023. Por etapa, os Anos Finais apresentam TDI média de 32,3, enquanto os Anos Iniciais apresentam 17,5. No ranking de médias por UF, Sergipe aparece com 37,2 e São Paulo com 8,6 nos extremos visíveis do painel. A variação territorial é negativa para todas as barras exibidas, indicando redução da distorção no intervalo considerado, embora em magnitudes diferentes entre as UFs.

A redução é um resultado favorável sob a interpretação do indicador, pois a TDI expressa a proporção de estudantes em situação de distorção entre idade e série (INEP, 2026); portanto, valores menores indicam menor incidência dessa condição no recorte analisado. Contudo, a permanência de médias elevadas em determinadas UFs e a diferença entre etapas mostram que o problema não desaparece de forma homogênea. Leal (2025) discute a distorção idade-série como um fenômeno associado a fatores pedagógicos, sociais e estruturais, entre eles repetência e vulnerabilidade socioeconômica, aspectos que não são modelados pelo dashboard.

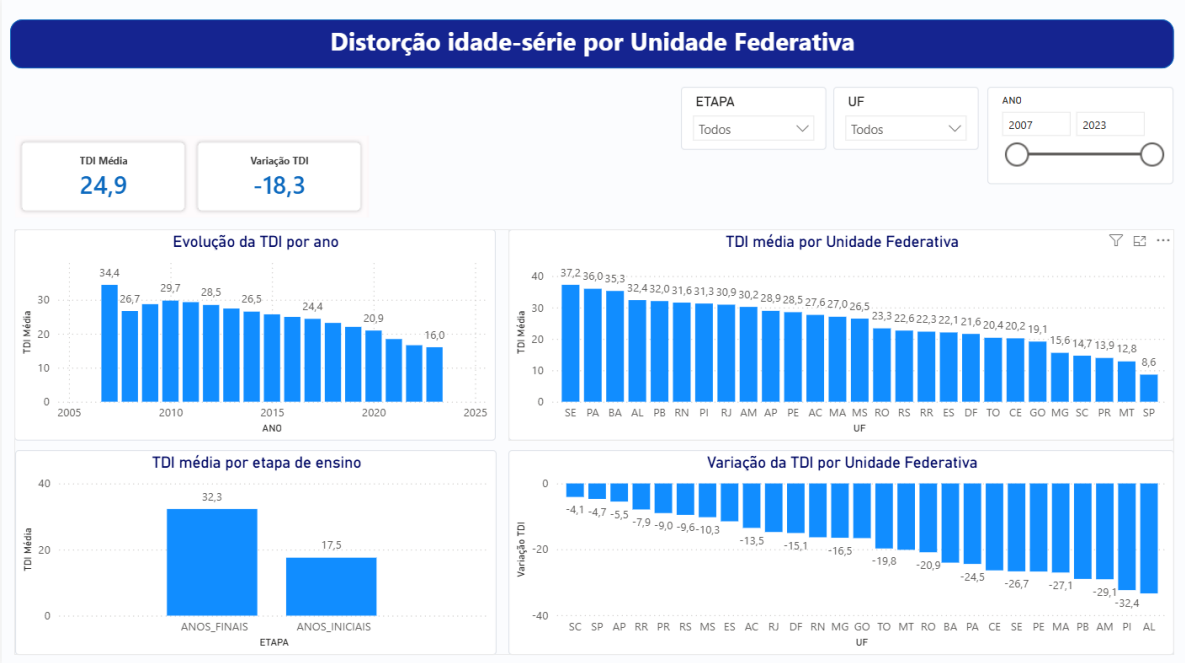


Figura 8 – Distorção idade-série por Unidade Federativa e etapa de ensino.

Fonte: Elaborado pelo autor a partir do dashboard do projeto (2026).

5.7 Resultados da PND 2025

A PND é analisada separadamente das séries históricas. A população analítica contém 759.140 registros. A classificação utilizada no projeto é baseada em `NT_OBJ` e nos pontos de corte documentados para a PND (Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2025a; Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2026). Aplicando essa regra à população analítica, obtiveram-se 265.932 não proficientes, 304.638 participantes no Padrão 1 e 188.570 no Padrão 2. A soma dos padrões 1 e 2 corresponde a 493.208 proficientes, equivalentes a 64,97% da população analítica.

Na Figura 9, os cartões arredondam esse resultado para 759 mil participantes e 65,0% de proficientes. A Nota Objetiva Média exibida é 57,5 e a Nota Geral Média é 57,3. Os gráficos complementam a leitura com percentual de proficientes por área, percentual de proficientes por UF, nota objetiva média por área e distribuição dos três padrões por UF.

A classificação deve ser interpretada nos termos dos pontos de corte aplicados à nota objetiva (Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2025a; Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2026). Não se trata de aprovação ou reprovação e o limite de 50 pontos não representa simplesmente 50% de acertos. A distribuição por UF e área também é descritiva da população analítica da prova. Como `UF_PROVA` representa a Unidade Federativa de aplicação, diferenças ter-

ritoriais não devem ser interpretadas automaticamente como características de residência dos participantes.



Figura 9 – Resultados da Prova Nacional Docente de 2025.

Fonte: Elaborado pelo autor a partir do dashboard do projeto (2026).

5.8 Limitações observadas nos resultados

Os resultados devem ser lidos em conjunto com as limitações metodológicas apresentadas na Seção 4.10. Em particular, as fontes diferem em periodicidade, nível de agregação e categorias históricas, enquanto a análise foi harmonizada principalmente por UF, rede pública e etapa de ensino.

Os cartões de média no Power BI calculam a média das linhas presentes no contexto de filtro. Quando todas as UFs estão selecionadas, esse valor não equivale automaticamente a um indicador nacional ponderado por matrícula ou por quantidade de participantes. Assim, os números gerais do dashboard devem ser interpretados como sínteses do modelo analítico construído, e não como substitutos de estatísticas nacionais oficiais produzidas com outros ponderadores.

Por fim, nenhuma associação visual apresentada neste capítulo deve ser interpretada como relação de causa e efeito. O projeto foi desenhado para integração, rastreabilidade e exploração descritiva dos dados; investigações causais exigiriam desenho metodológico, variáveis de controle e técnicas estatísticas específicas.

Capítulo 6

Conclusão

Este trabalho investigou como uma arquitetura reprodutível de Engenharia de Dados pode integrar bases educacionais heterogêneas do INEP e disponibilizá-las de forma consistente para análise no Power BI. A questão de pesquisa foi respondida por meio da construção de um pipeline em Python organizado nas camadas Raw, Bronze, Silver e Gold, acompanhado de manifesto das fontes, hashes SHA-256, metadados de linhagem, validadores independentes e uma camada analítica consumida exclusivamente pelo Power BI.

O pipeline integrou IDEB, SAEB, Rendimento Escolar e TDI no recorte histórico de 2007 a 2023 e incorporou a PND 2025 como análise complementar. A solução final materializou cinco tabelas fato e cinco dimensões. A validação global confirmou a integridade estrutural do modelo e as correspondências definidas entre as camadas, retornando `MODELO DIMENSIONAL GOLD: OK`.

A construção mostrou que a integração de fontes oficiais exige mais do que reunir arquivos em uma ferramenta de visualização. Foi necessário tratar diferenças de formato, layout, periodicidade, granularidade e semântica de rede, além de documentar decisões específicas por indicador. No SAEB, por exemplo, a preservação dos agregados oficiais de UF evitou substituir o valor publicado por uma recomposição escolar que não reproduzia o resultado oficial. Na PND, a auditoria da população e o uso dos pontos de corte aplicados à `NT_OBJ` produziram uma classificação coerente com a documentação adotada no projeto.

O Power BI atuou como camada de consumo e análise. As 27 medidas DAX e as páginas do dashboard permitiram observar panorama histórico, desempenho por Unidade Federativa, associação descritiva entre aprendizagem e fluxo, variações territoriais, distorção idade-série e resultados da PND 2025. As medidas temporais foram implementadas de forma a usar o primeiro e o último ano com dado dentro do intervalo selecionado, respeitando a periodicidade anual de Rendimento e TDI e a periodicidade bienal de IDEB e SAEB.

Os resultados descritivos evidenciam trajetórias distintas entre indicadores e UFs. No panorama geral do modelo, observam-se aumento do IDEB, das proficiências e da apro-

vação ao longo de grande parte da série, acompanhado de redução da TDI. Na página específica de TDI, o intervalo 2007–2023 apresenta variação média de -18,3 pontos percentuais no contexto exibido, enquanto a PND reúne 759.140 participantes e 493.208 classificados como proficientes, correspondentes a 64,97% da população analítica. Esses resultados são descritivos e não demonstram relações causais.

A principal contribuição técnica do trabalho está na reprodutibilidade do percurso entre fonte e consumo analítico. O inventário de 54 arquivos Raw, a identificação por hashes, a documentação da origem, os validadores de cada camada, o orquestrador e os testes do repositório tornam explícitas decisões que, em um fluxo restrito à ferramenta de BI, poderiam permanecer ocultas. Os notebooks demonstrativos complementam essa documentação, sem substituir os scripts oficiais do pipeline.

A automação da aquisição complementa esse percurso ao selecionar, extrair e organizar os insumos oficiais conforme o manifesto. A comparação do conteúdo protegido permite incorporar alterações físicas equivalentes sem aceitar mudanças históricas silenciosas, mantendo backup, diagnóstico e rastreabilidade das atualizações.

As limitações permanecem relevantes. A série histórica é harmonizada principalmente em nível de UF, rede pública e etapas agregadas, o que impede inferências sobre escolas ou municípios. As fontes possuem metodologias e layouts que mudam ao longo do tempo; SAEB apresenta particularidade de rede em 2007 e 2009; IDEB e SAEB são bienais; a PND possui apenas 2025; e as médias do dashboard não equivalem automaticamente a médias nacionais ponderadas. Além disso, as visualizações não permitem inferência causal.

Dessa forma, conclui-se que a arquitetura desenvolvida atingiu o objetivo proposto: bases públicas heterogêneas foram integradas em um pipeline documentado, validado e rastreável, chegando a um modelo dimensional consistente para exploração no Power BI. A contribuição do trabalho está tanto no produto analítico final quanto na explicitação do processo de Engenharia de Dados necessário para produzi-lo.

6.1 Principais Contribuições

As principais contribuições podem ser sintetizadas em cinco eixos. Primeiro, a integração de fontes educacionais heterogêneas do INEP em um fluxo único. Segundo, a arquitetura em camadas, que separa preservação, ingestão, harmonização e consumo analítico. Terceiro, a rastreabilidade e a reprodutibilidade, apoiadas por manifesto, hashes, linhagem, validadores, testes e orquestração. Quarto, a modelagem dimensional com cinco fatos e cinco dimensões. Quinto, a disponibilização dos dados em um modelo semântico com 27 medidas DAX e dashboards temáticos.

No componente territorial, a padronização histórica por Unidade Federativa viabilizou a integração entre fontes com diferentes estruturas. Para a PND, o modelo preservou

também o código do município de aplicação e a relação ativa com `DIM_MUNICIPIO`, sem criar uma relação direta entre essa dimensão e `DIM_UF`, evitando ambiguidade de filtro.

A incorporação da PND 2025 demonstrou a possibilidade de integrar uma fonte de granularidade individual ao mesmo ambiente analítico sem tratá-la como continuação artificial da série histórica da Educação Básica. A separação entre a análise histórica e a PND preservou a interpretação de cada fonte.

6.2 Trabalhos Futuros

Como trabalhos futuros, sugere-se ampliar o modelo com outras bases do INEP, como Censo Escolar, infraestrutura, matrículas, turmas e formação docente. A inclusão dessas fontes pode permitir análises adicionais, desde que cada nova base passe pelo mesmo processo de auditoria, documentação de fonte, harmonização e validação.

Outra possibilidade é aprofundar a granularidade territorial ou institucional. O presente trabalho prioriza UFs na análise histórica; pesquisas futuras podem desenvolver recortes municipais ou escolares quando houver compatibilidade de fonte, grão e metodologia.

Também podem ser incorporados indicadores socioeconômicos de instituições como IBGE ou IPEA. Essa expansão permitiria explorar associações mais amplas entre contexto social e indicadores educacionais, sem confundir análise descritiva com inferência causal.

Em estudos futuros, técnicas estatísticas ou de ciência de dados podem ser utilizadas para correlação, regressão, agrupamento ou séries temporais. Caso o objetivo seja investigar causalidade, será necessário um desenho específico de pesquisa, com hipóteses, controles e métodos adequados.

No caso da PND, novas edições poderão permitir a construção de uma série própria, separada dos indicadores históricos deste trabalho. Também é possível evoluir a publicação do dashboard para ambiente institucional ou público, com atenção a usabilidade, atualização automatizada e governança dos dados.

6.3 Perspectivas de produção bibliográfica

Até o momento da finalização deste trabalho, não houve publicação de artigo científico resultante diretamente da pesquisa. O projeto, entretanto, oferece material para futuras produções sobre pipelines reprodutíveis de dados educacionais, qualidade e linhagem de dados públicos, modelagem dimensional aplicada ao INEP, integração de indicadores da Educação Básica e visualização analítica em Power BI.

Possíveis trabalhos derivados incluem estudos sobre reprodutibilidade de pipelines educacionais, comparação de metodologias de publicação entre edições do SAEB, integração

de indicadores históricos com novas fontes e uso de visualizações para comunicação de resultados educacionais.

Referências

ANDRADE, M. E. d.; ANDRADE, M. E. d. Desigualdades de aprendizagem entre escolas rurais e urbanas: Evidências descritivas a partir do saeb 2023. **Cadernos da FUCAMP**, v. 53, p. 17–32, 2026. ISSN 2236-9929.

CARVALHO, V. W. d. **Estudo de Maturidade Analítica na Gestão Energética da UFRN: do Diagnóstico de Dados Históricos à Proposta de Arquitetura Data-Driven**. Natal: Universidade Federal do Rio Grande do Norte, 2025. Trabalho de Conclusão de Curso (Bacharelado em Engenharia Elétrica).

DIAS, A. A. et al. Avaliação e indicadores educacionais, políticas públicas e escola: o Índice de desenvolvimento da educação básica (ideb) – interpretação, metas e resultados. **Aurum Revista Multidisciplinar**, v. 2, n. 8, p. 1–22, 2026. ISSN 3085-7783.

FERREIRA, M. K. **Dados de Pesquisa: Contribuição da Infraestrutura para a Promoção da Reprodutibilidade e do Reúso**. Tese (Doutorado) — Universidade Federal do Rio Grande do Sul, Porto Alegre, 2024.

GIL, A. C. **Como Elaborar Projetos de Pesquisa**. 4. ed. São Paulo: Atlas, 2002. ISBN 85-224-3169-8.

ILHA, L. B.; Moreira Junior, F. d. J. A construção de um data warehouse utilizando os indicadores educacionais do inep. **SciELO Preprints**, 2021. Preprint publicado em 3 maio 2021.

INEP. **Resultados do Índice de Desenvolvimento da Educação Básica (IDEB)**. Brasília: INEP, 2024. Disponível em: <https://www.gov.br/inep/pt-br/areas-de-atuacao/pesquisas-estatisticas-e-indicadores/ideb/resultados>. Acesso em: 23 jun. 2026.

_____. **Microdados do Sistema de Avaliação da Educação Básica (SAEB)**. Brasília: INEP, 2025. Disponível em: <https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/saeb>. Acesso em: 23 jun. 2026.

_____. **Taxas de Rendimento Escolar**. Brasília: INEP, 2025. Disponível em: <https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/indicadores-educacionais/taxas-de-rendimento-escolar>. Acesso em: 23 jun. 2026.

_____. **Taxas de Distorção Idade-Série**. Brasília: INEP, 2026. Disponível em: <https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/indicadores-educacionais/taxas-de-distorcao-idade-serie>. Acesso em: 23 jun. 2026.

Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. **Nota Técnica nº 44/2025/CEI/CGGI/DAES-INEP: metodologia de cálculo da nota geral dos participantes do Enade das Licenciaturas e da Prova Nacional Docente (PND), edições de 2025**. Brasília: INEP, 2025. Disponível em: <https://download.inep.gov.br/pnd/notas_tecnicas/SEI_1854638_nota_tecnica_44.pdf>. Acesso em: 19 ago. 2026.

_____. **PND: Microdados da Prova Nacional Docente**. 2025. Disponível em: <https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/pnd>. Acesso em: 8 jul. 2026.

_____. **Nota Técnica nº 1/2026/GPP/GAB-INEP: procedimentos para estabelecimento dos pontos de corte da Prova Nacional Docente por meio do Método de Angoff Modificado e transposição para a escala de proficiência da TRI**. Brasília: INEP, 2026. Disponível em: <https://download.inep.gov.br/pnd/notas_tecnicas/SEI_1873050_nota_tecnica_1.pdf>. Acesso em: 19 ago. 2026.

KIMBALL, R.; ROSS, M. **The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling**. 3. ed. Indianapolis: John Wiley & Sons, 2013. ISBN 978-1-118-53080-1.

LEAL, M. I. d. O. **A Distorção Idade-Série nos Anos Finais do Ensino Fundamental**. Mariana, MG: Universidade Federal de Ouro Preto, 2025. Trabalho de Conclusão de Curso (Licenciatura em Pedagogia), 31 f.

LOH, S. **BI na Era do Big Data para Cientistas de Dados: Indo Além de Cubos e Dashboards na Busca pelos Porquês, Explicações e Padrões**. 1. ed. Porto Alegre: Stanley Loh, 2014. ISBN 978-85-916683-1-1.

Martins Filho, F. E. R. **Indicadores de Desempenho Escolar: uma Abordagem Baseada em Visualização de Dados**. Sobral: Universidade Federal do Ceará, 2025. Trabalho de Conclusão de Curso (Graduação em Engenharia de Computação), Campus de Sobral, 63 f.

Microsoft. **O que é o Power BI?** Microsoft Learn, 2025. Disponível em: <https://learn.microsoft.com/pt-br/power-bi/fundamentals/power-bi-overview>. Acesso em: 23 jun. 2026.

MORENO, L. R. B.; OLIVEIRA, A. M. d. Tomada de decisão e qualidade dos dados: Percepções sobre acurácia, completude, consistência e disponibilidade. **Revista Estratégias e Soluções**, 2026.

PRODANOV, C. C.; FREITAS, E. C. d. **Metodologia do Trabalho Científico: Métodos e Técnicas da Pesquisa e do Trabalho Acadêmico**. 2. ed. Novo Hamburgo: Feevale, 2013. ISBN 978-85-7717-158-3.

SILVA, F. I. d. **Proveniência de Dados e Metadados em Repositórios de Dados de Pesquisa**. Dissertação (Mestrado) — Universidade Federal de São Carlos, São Carlos, 2025.

SOARES, R. d. C. et al. Mineração de dados da educação básica brasileira usando as bases do inep: Uma revisão sistemática da literatura. **RENOTE**, v. 19, n. 1, p. 361–370, 2021.

WANDERLEY, P. F. **Uso de Business Intelligence para Avaliação de Indicadores de Desempenho na Educação Básica: um Estudo de Caso no Estado do Acre**. Campina Grande: Universidade Federal de Campina Grande, 2021. Trabalho de Conclusão de Curso – Artigo (Bacharelado em Ciência da Computação), 13 f.

Apêndices

APÊNDICE **A**

Mapeamento histórico dos layouts

Este apêndice registra as correspondências utilizadas para transformar as estruturas físicas preservadas na Bronze nas estruturas semânticas da Silver. A notação `col_NNN` identifica a posição física da coluna na fonte. Ela é deliberadamente neutra: o significado é atribuído somente após a leitura do cabeçalho, do dicionário ou da auditoria correspondente.

A.1 Rendimento Escolar

O Rendimento Escolar possui cinco configurações históricas de layout. Em todas elas, `col_001` contém o ano; a seleção mantém `Localizacao = Total`, o agregado público da edição e as 27 UFs. Cada linha selecionada é convertida em seis observações: duas etapas multiplicadas pelos três indicadores.

Tabela 5 – Mapeamento físico do Rendimento Escolar por período.

Período	Identificação	Aprovação AI/AF	Reprovação AI/AF	Abandono AI/AF	Categoria de rede	Observação
2007	região col_002; UF col_003; localização col_004; rede col_005	col_015/col_016	col_033/col_034	col_051/col_052	Publico	Possui coluna própria de região.
2008–2010	UF col_002; localização col_003; rede col_004	col_014/col_015	col_032/col_033	col_050/col_051	Publico	Não possui o deslocamento da coluna de região observado em 2007.
2011–2014	UF col_002; localização col_003; rede col_004	col_006/col_007	col_024/col_025	col_042/col_043	Publico	A fonte passa a explicitar colunas agregadas de Anos Iniciais e Finais.
2015	UF col_002; localização col_003; rede col_004	col_006/col_007	col_024/col_025	col_042/col_043	Publica	UF apresentada por nome e mudança de gênero na categoria pública.
2016	região col_002; UF col_003; localização col_004; rede col_005	col_007/col_008	col_025/col_026	col_043/col_044	Publica	Retorno da coluna de região e deslocamento das métricas.
2017–2023	unidade geográfica col_002; localização col_003; rede col_004	col_006/col_007	col_024/col_025	col_042/col_043	Publica	Brasil, regiões e UFs compartilham o campo geográfico; somente UFs reconhecidas são mantidas.

As métricas são convertidas para `INDICADOR = APROVACAO`, `REPROVACAO` ou `ABANDONO`; o valor correspondente é armazenado em `VALOR`. Os campos `REDE_ORIGEM`, `LOCALIZACAO_ORIGEM`, `ARQUIVO_ORIGEM`, `LINHA_ORIGEM_BRONZE` e `COLUNA_ORIGEM` preservam a proveniência.

A.2 Taxa de Distorção Idade-Série

A TDI também possui cinco configurações. Cada linha pública-total selecionada produz duas observações, uma para cada etapa do Ensino Fundamental.

Tabela 6 – Mapeamento físico da TDI por período.

Período	**Identificação**	**TDI Anos Iniciais**	**TDI Anos Finais**	**Categoria de rede**	**Observação**
2007–2010	região `col_002`; UF `col_003`; localização `col_004`; rede `col_005`	`col_015`	`col_016`	`Publico`	Uma linha pública-total por UF.
2011–2014	região `col_002`; UF `col_003`; localização `col_004`; rede `col_005`	`col_007`	`col_008`	`Publico`	Mudança das posições das etapas.
2015	região `col_002`; código UF `col_003`; sigla UF `col_004`; localização `col_005`; rede `col_006`	`col_008`	`col_009`	`Publica`	Código e sigla da UF aparecem em campos separados.
2016	região `col_002`; UF `col_003`; localização `col_004`; rede `col_005`	`col_007`	`col_008`	`Publica`	UF representada por nome completo.
2017–2023	unidade geográfica `col_002`; localização `col_003`; rede `col_004`	`col_006`	`col_007`	`Publica`	Há 33 linhas públicas-totais: Brasil, cinco regiões e 27 UFs; o modelo mantém as 27 UFs.

O valor é armazenado em TDI; a origem permanece registrada em REDE_ORIGEM, LOCALIZACAO_ORIGEM, ARQUIVO_ORIGEM, LINHA_ORIGEM_BRONZE e COLUNA_ORIGEM.

A.3 IDEB

O workbook do IDEB é preservado em três Bronzes, correspondentes às abas UF e Regioes (AI), UF e Regioes (AF) e UF e Regioes (EM). A primeira coluna física contém a geografia e a segunda a categoria de rede. O Ensino Médio permanece preservado na Bronze, mas não integra o recorte analítico.

Tabela 7 – Mapeamento do IDEB para a Silver.

Componente	**Origem**	**Regra**	**Destino**
Etapa	abas AI e AF	AI é convertida em ANOS_INICIAIS; AF em ANOS_FINAIS.	ETAPA
Geografia	col_001	Nome ou alias convertido por mapeamento exato; Brasil e regiões não geram sigla e ficam fora do grão.	UF; original em GEOGRAFIA_ORIGEM
Rede	col_002	Seleção da categoria normalizada publica (4).	REDE=PUBLICA; original em REDE_ORIGEM
Ano e medida	linha técnica do cabeçalho	Localização única de VL_OBSERVADO_2007, VL_OBSERVADO_2009, ..., VL_OBSERVADO_2023. A posição física não é presumida.	ANO e IDEB; posição em COLUNA_ORIGEM
Proveniência	metadados Bronze	Preservação de arquivo, aba e linha.	ARQUIVO_ORIGEM, ABA_ORIGEM, LINHA_ORIGEM_BRONZE

Fonte: Elaborado pelo autor a partir do transformador Silver do IDEB (2026).

A busca pelo nome técnico evita utilizar o cabeçalho visual 20215 (grafia presente no arquivo de origem), observado na apresentação de 2021. O valor correto é identificado por VL_OBSERVADO_2021. O arquivo físico pode conter 2005 e 2025, mas somente 2007, 2009, 2011, 2013, 2015, 2017, 2019, 2021 e 2023 são transformados nesta versão.

A.4 SAEB

O SAEB exigiu regras distintas por edição. A tabela seguinte registra a identificação da rede, localização, etapa, disciplina e medida efetivamente utilizada.

Tabela 8 – Mapeamento histórico do SAEB.

Edição	Seleção de rede e localização	Etapa	Disciplina e medida	Particularidade
2007 e 2009	`DEPENDENCIA_ADM = Total - Estadual e Municipal`; `LOCALIZACAO = Total`; `CAPITAL = Total`.	Anos Iniciais pelas variáveis da 4ª série; Anos Finais pelas variáveis da 8ª série.	AI/LP `MEDIA_4_LP`; AI/MT `MEDIA_4_MT`; AF/LP `MEDIA_8_LP`; AF/MT `MEDIA_8_MT`.	O agregado disponível não inclui rede federal de forma explícita; essa limitação é preservada em `REDE_ORIGEM`.
2011	`ID_TIPO_REDE=5`; `ID_LOCALIZACAO=0`; `ID_CAPITAL=0`.	`ID_SERIE=5` para Anos Iniciais; `ID_SERIE=9` para Anos Finais.	`MEDIA_LP` é convertida em `LP`; `MEDIA_MT`, em `MT`.	Fonte tabular com códigos identificados no dicionário da edição.
2013 e 2015	`col_002 = Total - Federal, Estadual e Municipal`; `col_003 = Total`; `col_004 = Total`.	AI em `col_005`/`col_006`; AF em `col_007`/`col_008`.	`col_005`: AI/LP; `col_006`: AI/MT; `col_007`: AF/LP; `col_008`: AF/MT.	Cabeçalho hierárquico em três linhas; não são inventados nomes técnicos ausentes. Em 2015, zero significa média não calculável para o estrato e é convertido em ausência.
2017, 2019 e 2021	`DEPENDENCIA_ADM = Total - Federal, Estadual e Municipal`; `LOCALIZACAO = Total`; `CAPITAL = Total`.	Campos de 5º ano são AI; campos de 9º ano são AF.	AI/LP `MEDIA_5_LP`; AI/MT `MEDIA_5_MT`; AF/LP `MEDIA_9_LP`; AF/MT `MEDIA_9_MT`.	Cabeçalhos técnicos são localizados na linha auditada da própria edição.
2023	Mesma seleção textual das edições recentes, aplicada à aba oficial `Estados`.	Campos de 5º ano são AI; campos de 9º ano são AF.	`MEDIA_5_LP`, `MEDIA_5_MT`, `MEDIA_9_LP` e `MEDIA_9_MT`.	Usa `<saeb_2023_resultados_uf.parquet>`; a Bronze escolar é preservada, mas não é usada para reconstruir a média estadual.

Em todas as edições, a saída utiliza ETAPA igual a ANOS_INICIAIS ou ANOS_FINAIS, DISCIPLINA igual a LP ou MT e REDE igual a PUBLICA. A Silver mantém os seguintes campos de proveniência:

- ❏ REDE_ORIGEM, LOCALIZACAO_ORIGEM e CAPITAL_ORIGEM;
- ❏ ARQUIVO_ORIGEM, ABA_ORIGEM e LINHA_ORIGEM_BRONZE;
- ❏ COLUNA_ORIGEM e GRANULARIDADE_ORIGEM.

A.5 PND 2025

O arquivo principal da PND contém 26 campos separados por ponto e vírgula. A Bronze preserva todos como texto, além da linha física do cabeçalho. A Silver lê os campos seguintes pelas posições confirmadas no cabeçalho.

Tabela 9 – Mapeamento físico dos campos utilizados da PND 2025.

Posição Bronze	Campo oficial	Tipo Silver	Uso
col_001	NU_ANO	inteiro	ano da aplicação
col_002	CO_GRUPO	inteiro	código da área da prova
col_003	CO_MUNICIPIO_PROVA	inteiro	município de aplicação
col_004	SG_UF_MUNICIPIO_PROVA	texto	origem de UF_PROVA
col_005	TP_INSCRICAO_PND	inteiro	perfil de inscrição preservado
col_006	IN_REAPLICACAO	inteiro	aplicação ou reaplicação
col_007	CO_CADERNO	inteiro	caderno da prova
col_011	TP_PRES	inteiro	condição obrigatória da população
col_012	TP_SIT_DISC	inteiro	situação da questão discursiva
col_013	PROFICIENCIA	decimal	proficiência TRI objetiva
col_014	NT_OBJ	decimal	nota objetiva
col_015	NT_DIS	decimal	nota discursiva
col_016	NT_GER	decimal	nota geral
col_017	QT_ACERTOS	inteiro	quantidade de acertos

Fonte: Elaborado pelo autor a partir do dicionário e do cabeçalho auditado da PND 2025.

Os campos col_008 a col_010 correspondem aos vetores DS_VT_GAB_OBJ, DS_VT_ESC_OBJ e DS_VT_ACE_OBJ; col_018 a col_026 correspondem a CO_RS_I1 a CO_RS_I9. Eles não são transportados para a fato Silver porque não integram as análises definidas, mas permanecem integralmente na Bronze.

APÊNDICE **B**

Dicionário de harmonização de categorias

Este apêndice apresenta as categorias e os códigos que recebem interpretação semântica durante a transformação. A harmonização cria valores comuns para análise, mas preserva a representação original em campos de proveniência sempre que ela é necessária para auditoria.

B.1 Unidades Federativas

Siglas oficiais já existentes são preservadas. Nomes completos são convertidos por igualdade explícita após remoção apenas de espaços excedentes, diferenças entre maiúsculas e minúsculas e acentuação usada na comparação. Não é utilizada correspondência aproximada.

Tabela 10 – Mapeamento de nomes das Unidades Federativas para siglas.

Nome	**UF**	**Nome**	**UF**	**Nome**	**UF**
Acre	AC	Alagoas	AL	Amapá	AP
Amazonas	AM	Bahia	BA	Ceará	CE
Distrito Federal	DF	Espírito Santo	ES	Goiás	GO
Maranhão	MA	Mato Grosso	MT	Mato Grosso do Sul	MS
Minas Gerais	MG	Pará	PA	Paraíba	PB
Paraná	PR	Pernambuco	PE	Piauí	PI
Rio de Janeiro	RJ	Rio Grande do Norte	RN	Rio Grande do Sul	RS
Rondônia	RO	Roraima	RR	Santa Catarina	SC
São Paulo	SP	Sergipe	SE	Tocantins	TO

Fonte: Elaborado pelo autor (2026).

No IDEB, também foram observados e mapeados os aliases `R. G. do Norte` para `RN`, `R. G. do Sul` para `RS` e `M. G. do Sul` para `MS`. Valores como Brasil e nomes de regiões não recebem sigla de UF e, por isso, não integram o grão estadual.

B.2 Rede pública e localização

Tabela 11 – Harmonização da rede pública por fonte.

Indicador	Período	Representação original selecionada	Valor canônico	Interpretação e restrição
Rendimento	2007–2014	`Publico` e localização `Total`	`PUBLICA`	Agregado público publicado; não é média calculada entre dependências.
Rendimento	2015–2023	`Publica` e localização `Total`	`PUBLICA`	Mesmo conceito analítico, com mudança textual da fonte.
TDI	2007–2014	`Publico` e localização `Total`	`PUBLICA`	A categoria `Total` de dependência não substitui o agregado público.
TDI	2015–2023	`Publica` e localização `Total`	`PUBLICA`	Brasil e regiões são retirados após identificação explícita das UFs.
IDEB	nove edições	`Publica (4)`	`PUBLICA`	Categoria oficial do workbook; o IDEB não é recalculado a partir das redes individuais.
SAEB	2007 e 2009	`Total - Estadual e Municipal`; localização e capital `Total`	`PUBLICA`	Exceção histórica: a categoria utilizada não apresenta a rede federal; a grafia original é preservada.
SAEB	2011	`ID_TIPO_REDE=5`; `ID_LOCALIZACAO=0`; `ID_CAPITAL=0`	`PUBLICA`	Códigos identificados no dicionário e confirmados pela auditoria.
SAEB	2013–2023	`Total - Federal, Estadual e Municipal`; localização e capital `Total`	`PUBLICA`	Agregado oficial; não há média simples entre as três dependências.

Fonte: Elaborado pelo autor a partir das categorias auditadas nas fontes (2026).

Não são utilizadas como equivalências automáticas: rede `Total` quando inclui a rede privada; média ou soma entre redes federal, estadual e municipal; recálculo do IDEB público; transformação de categoria privada em pública; ou substituição de agregado oficial por estimativa própria.

B.3 Etapas, indicadores e disciplinas

Tabela 12 – Categorias analíticas padronizadas.

Dimensão	**Representações de origem**	**Valor canônico**
Etapa	Anos Iniciais; 4ª série; 5º ano; `ID_SERIE=5`; aba AI	`ANOS_INICIAIS`
Etapa	Anos Finais; 8ª série; 9º ano; `ID_SERIE=9`; aba AF	`ANOS_FINAIS`
Rendimento	taxa de aprovação nas respectivas colunas	`APROVACAO`
Rendimento	taxa de reprovação nas respectivas colunas	`REPROVACAO`
Rendimento	taxa de abandono nas respectivas colunas	`ABANDONO`
SAEB	Língua Portuguesa; `MEDIA_LP`; campos `MEDIA_4_LP`, `MEDIA_5_LP`, `MEDIA_8_LP` ou `MEDIA_9_LP`, conforme etapa e edição	`LP`
SAEB	Matemática; `MEDIA_MT`; campos `MEDIA_4_MT`, `MEDIA_5_MT`, `MEDIA_8_MT` ou `MEDIA_9_MT`, conforme etapa e edição	`MT`

Fonte: Elaborado pelo autor (2026).

A associação entre 4ª/8ª séries e 5º/9º anos respeita a nomenclatura histórica de cada edição da fonte; ambas são consolidadas nas etapas agregadas do Ensino Fundamental utilizadas pelo projeto.

B.4 Códigos da PND 2025

B.4.1 Áreas da prova

O campo `CO_GRUPO` é convertido para `AREA_PROVA` por um dicionário fechado. Um código não documentado provoca falha na transformação.

Tabela 13 – Códigos de área da PND 2025.

Código	Rótulo preservado em AREA_PROVA
702	MATEMÁTICA (LICENCIATURA)
904	LETRAS - PORTUGUÊS (LICENCIATURA)
905	LETRAS - PORTUGUÊS E INGLÊS (LICENCIATURA)
906	LETRAS - PORTUGUÊS E ESPANHOL (LICENCIATURA)
1402	FÍSICA (LICENCIATURA)
1502	QUÍMICA (LICENCIATURA)
1602	CIÊNCIAS BIOLÓGICAS (LICENCIATURA)
2001	PEDAGOGIA (LICENCIATURA)
2402	HISTÓRIA (LICENCIATURA)
2501	ARTES VISUAIS (LICENCIATURA)
3002	GEOGRAFIA (LICENCIATURA)
3202	FILOSOFIA (LICENCIATURA)
3502	EDUCAÇÃO FÍSICA (LICENCIATURA)
4005	CIÊNCIA DA COMPUTAÇÃO (LICENCIATURA)
4301	MÚSICA (LICENCIATURA)
5402	CIÊNCIAS SOCIAIS (LICENCIATURA)
6407	LETRAS - INGLÊS (LICENCIATURA)

Fonte: Dicionário de Variáveis da PND 2025, organizado pelo autor.

B.4.2 Inscrição, aplicação e presença

Tabela 14 – Códigos categóricos da PND preservados na Silver.

Campo	Código	Significado documentado
TP_INSCRICAO_PND	1	Concluinte Enade
TP_INSCRICAO_PND	2	Demais participantes
TP_INSCRICAO_PND	3	Concluinte Enade que optou por realizar a prova em área diferente da inscrição no Enade
IN_REAPLICACAO	0	Aplicação realizada em 26/10/2025
IN_REAPLICACAO	1	Reaplicação realizada em 30/11/2025
CO_CADERNO	1–4	Cadernos da aplicação
CO_CADERNO	5	Caderno da reaplicação
TP_PRES	222	Ausente
TP_PRES	334	Eliminado por participação indevida
TP_PRES	444	Ausente devido a múltiplas inscrições
TP_PRES	555	Presente com resultado válido
TP_PRES	888	Presente, com resultado desconsiderado pelo INEP
TP_SIT_DISC	222	Não se aplica, participante ausente
TP_SIT_DISC	333	Questão em branco, participante presente, nota zero
TP_SIT_DISC	335	Questão zerada por resposta nula, nota zero
TP_SIT_DISC	336	Resposta divergente da temática, nota zero
TP_SIT_DISC	555	Questão com resultado válido

Fonte: Dicionário de Variáveis da PND 2025, organizado pelo autor.

Não é aplicado filtro TP_SIT_DISC=555. Os códigos 333, 335 e 336 possuem nota zero válida e participam do cálculo oficial. A população analítica exige TP_PRES=555, independentemente do tipo de inscrição, da aplicação ou reaplicação e do caderno, desde que os cinco resultados analíticos estejam completos.

B.4.3 Padrão de desempenho

Tabela 15 – Classificação de desempenho derivada de `NT_OBJ`.

Condição	**Categoria materializada**	**Uso semântico**
`NT_OBJ < 50`	`NAO_PROFICIENTE`	não proficiente
`50 <= NT_OBJ < 70`	`PADRAO_1`	proficiente, padrão 1
`NT_OBJ >= 70`	`PADRAO_2`	proficiente, padrão 2

Fonte: Notas Técnicas oficiais do INEP citadas no corpo do trabalho.

B.5 Marcadores de ausência e conversão numérica

Tabela 16 – Tratamento de ausência e precisão por indicador.

Indicador	**Marcadores convertidos em ausência**	**Zero**	**Precisão e domínio**
Rendimento	nulo, vazio e `-`	preservado como valor substantivo	uma casa decimal; 0 a 100
TDI	nulo, vazio e `-`	preservado como valor substantivo	uma casa decimal; 0 a 100
IDEB	nulo, vazio, `-` e `-`	preservado	uma casa decimal; 0 a 10
SAEB	nulo, vazio, `-` e `-`	preservado, exceto em 2015, quando a própria fonte o define como média não calculável para o estrato	duas casas decimais; 0 a 500
PND	nulo, vazio e literal `NA`	preservado quando publicado como resultado	sem arredondamento analítico; `QT_ACERTOS` não pode ser negativo

Fonte: Elaborado pelo autor a partir das regras dos transformadores (2026).

Não é realizada imputação. Na PND, valores negativos de `PROFICIENCIA` são preservados por pertencerem à escala publicada; nenhum limite inferior não documentado é imposto a `PROFICIENCIA`, `NT_OBJ`, `NT_DIS` ou `NT_GER`.

APÊNDICE C

Critérios de inclusão e exclusão

Este apêndice distingue exclusão analítica de exclusão física. A Raw mantém os arquivos oficiais inventariados e a Bronze preserva as estruturas selecionadas para ingestão sem aplicar o recorte final. Os filtros são executados na Silver. Assim, um registro, coluna ou nível de agregação ausente da Gold não foi necessariamente apagado: ele pode permanecer disponível na Raw ou na Bronze para auditoria e para pesquisas futuras com outro objetivo.

C.1 Recortes por indicador

Tabela 17 – Critérios de seleção e dados fora do recorte analítico.

Indicador	**Incluído na Silver**	**Não incluído na Silver/Gold**	**Justificativa e preservação**
Rendimento Escolar	Anos de 2007 a 2023; 27 UFs; localização `Total`; agregado oficial `Publico/Publica`; Anos Iniciais e Finais; Aprovação, Reprovação e Abandono.	Brasil e regiões; localização urbana/rural; rede privada; categorias federal, estadual e municipal separadas; outras etapas e demais colunas da planilha.	Recorte comum da pesquisa em nível estadual e rede pública. Não há recomposição por média entre redes. A Bronze preserva 17 layouts anuais e todas as respectivas colunas.
TDI	Anos de 2007 a 2023; 27 UFs; localização `Total`; agregado oficial `Publico/Publica`; Anos Iniciais e Finais.	Brasil e regiões; localização urbana/rural; rede privada; dependências separadas; outras etapas e colunas não utilizadas.	Mesmo recorte territorial e de rede adotado para a série histórica. A categoria de dependência `Total` não é usada como sinônimo de pública. Os dados continuam na Bronze.
IDEB	Nove edições de 2007 a 2023; 27 UFs; abas de Anos Iniciais e Finais; categoria `Publica (4)`; valor `VL_OBSERVADO_AAAA`.	Edição 2005; edição 2025 presente no arquivo físico; Ensino Médio; Brasil e regiões; outras redes; metas e componentes auxiliares do workbook.	O período e as etapas são definidos pelo escopo desta versão. As três abas e anos adicionais permanecem na Bronze, e a atualização do arquivo não amplia automaticamente a análise.
SAEB	Nove edições de 2007 a 2023; 27 UFs; agregado público oficial disponível; Anos Iniciais e Finais; Língua Portuguesa e Matemática; resultados em nível de UF.	Rede privada; localização ou capital desagregados; outras séries/etapas; outras categorias de rede; microdados e resultados escolares como fonte da fato; demais campos das fontes.	O grão comparável é UF por etapa e disciplina. Em 2023, a Bronze escolar permanece preservada, mas o resultado estadual publicado é obtido da Bronze agregada oficial porque médias escolares testadas não reproduziram o agregado.
PND 2025	Registros com `TP_PRES=555` e `PROFICIENCIA`, `NT_OBJ`, `NT_DIS`, `NT_GER` e `QT_ACERTOS` simultaneamente completos; todas as 27 UFs e 17 áreas presentes nessa população.	Ausentes, eliminados, múltiplas inscrições ausentes, resultados desconsiderados pelo INEP, presentes sem resultados completos; vetores de gabarito/escolha/acerto e respostas `CO_RS_I1`–`CO_RS_I9` fora da fato analítica.	A análise descreve participantes válidos com resultados disponíveis, sem imputação. Todos os 1.087.359 registros e as 26 colunas continuam preservados na Bronze.

As conclusões do trabalho são condicionais a esses recortes. Elas não devem ser generalizadas para rede privada, Ensino Médio, escolas, municípios ou todos os inscritos da PND. Esses universos demandariam nova definição de população e novas validações.

C.2 População analítica da PND

A PND permite uma comparação direta de registros, pois o grão individual é mantido da Bronze para a Silver. O diagnóstico utilizado antes do filtro está sintetizado na Tabela 18.

Tabela 18 – Composição da população analítica da PND 2025.

Condição observada	**Registros**
Registros de dados na Bronze, sem contar o cabeçalho preservado	1.087.359
Cinco resultados completos	759.152
Cinco resultados ausentes	328.207
Resultados parcialmente preenchidos	0
`TP_PRES=555`	760.106
`TP_PRES=555` e cinco resultados completos: incluídos	759.140
`TP_PRES=555` sem o conjunto completo: não incluídos	966
`TP_PRES=888` com cinco resultados completos: não incluídos	12

Fonte: Auditoria da população da PND 2025 realizada pelo projeto.

Os 328.207 registros com resultados ausentes incluem diferentes situações de presença, entre elas os 966 registros classificados como `TP_PRES=555`. A causa dessa combinação não foi identificada nos materiais examinados; por isso, não houve imputação nem reconstrução. Os 12 registros `TP_PRES=888` com resultados preenchidos foram excluídos porque o dicionário define essa categoria como resultado desconsiderado pelo INEP.

C.3 Cardinalidades e transformação do grão

Tabela 19 – Cardinalidades esperadas das tabelas analíticas.

Indicador	**Composição do grão**	**Silver**	**Gold**
Rendimento	17 anos × 27 UFs × 2 etapas × 3 indicadores	2.754	2.754
TDI	17 anos × 27 UFs × 2 etapas	918	918
IDEB	9 anos × 27 UFs × 2 etapas	486	486
SAEB	9 anos × 27 UFs × 2 etapas × 2 disciplinas	972	972
PND	registros individuais que atendem às duas condições da população	759.140	759.140

Fonte: Elaborado pelo autor a partir dos contratos de validação do pipeline (2026).

A igualdade entre Silver e Gold demonstra que a Gold projeta o conjunto analítico validado sem remover linhas. Nas quatro séries históricas, cada combinação esperada

permanece no grão mesmo quando a medida de origem é ausente; o campo de valor fica nulo e não há exclusão silenciosa da combinação.

C.4 Contagens preservadas na Bronze

Tabela 20 – Estruturas preservadas na camada Bronze.

Indicador	**Volume Bronze**	**Observação**
Rendimento	9.012 linhas	Dezessete arquivos anuais preservados com os campos e cabeçalhos técnicos de cada edição.
TDI	8.989 linhas	Dezessete arquivos anuais preservados; as diferenças de quantidade e posição de colunas não são uniformizadas na Bronze.
IDEB	150 linhas AI; 149 AF; 117 EM	Três abas preservadas separadamente, incluindo Ensino Médio e edições fora do recorte analítico.
SAEB	84.800 linhas físicas em 10 Parquets	Nove edições; em 2023 há uma Bronze escolar e outra do agregado oficial por UF.
PND	1.087.360 linhas, incluindo cabeçalho	1.087.359 registros substantivos e uma linha física de cabeçalho; 26 campos preservados.

Fonte: Relatórios de validação da camada Bronze do projeto.

Esses números não devem ser subtraídos diretamente das cardinalidades Silver para calcular "linhas descartadas". Rendimento, TDI, IDEB e SAEB passam de estruturas amplas para longas, contêm cabeçalhos preservados e podem reunir vários níveis geográficos ou categorias em uma mesma fonte. A comprovação de completude é feita pela seleção esperada, pela cobertura das combinações do grão e pela correspondência célula a célula, não por uma diferença bruta de contagem.

C.5 Colunas de proveniência e projeção Gold

Na Silver, a forma original relevante permanece disponível. Rendimento e TDI guardam rede, localização, arquivo, linha e coluna de origem. IDEB acrescenta geografia e aba. SAEB acrescenta capital e granularidade. A PND guarda arquivo, granularidade e linha física do participante.

A Gold mantém somente os atributos necessários ao modelo dimensional e às medidas do Power BI. A retirada dos campos detalhados de proveniência da Gold é uma projeção de consumo e não uma perda no pipeline, porque a Silver permanece como camada auditável entre a Bronze e a Gold.

APÊNDICE D

Controles de qualidade e rastreabilidade

Os controles do projeto verificam se os arquivos utilizados são identificáveis, se a ingestão preserva a fonte, se as transformações aplicam exatamente as regras declaradas e se o modelo dimensional mantém integridade. Eles não certificam a qualidade substantiva da coleta realizada pelo INEP nem substituem as notas metodológicas oficiais.

D.1 Controles por camada

Tabela 21 – Dimensões de qualidade verificadas ao longo do pipeline.

Camada	**Objetivo do controle**	**Verificações**	**Evidência produzida**
Raw	Identificar exatamente os insumos.	Inventário de 54 arquivos; existência; caminho; tamanho; fonte; período; finalidade; hash SHA-256 válido; comparação do hash calculado com o manifesto.	`docs/fontes_dados.csv`, `docs/raw_checksums_sha256.txt` e verificação executável do manifesto.
Bronze	Demonstrar que a ingestão não alterou silenciosamente o conteúdo.	Arquivo e aba esperados; quantidade de linhas e colunas; sequência de `col_NNN`; posição do cabeçalho; metadados obrigatórios; correspondência com a Raw; hash da fonte; preservação de tipos heterogêneos como texto quando necessário.	Parquets por fonte e validadores independentes de cada indicador.
Silver	Comprovar o recorte e a harmonização semântica.	Período; 27 UFs; redes, etapas, disciplinas e indicadores permitidos; domínios numéricos; marcadores de ausência; cardinalidade; unicidade do grão; correspondência de cada valor com arquivo, aba, linha e coluna Bronze; falha diante de categoria desconhecida.	Arquivos harmonizados, campos de proveniência e relatórios dos validadores Silver.
Gold	Garantir que a camada de consumo reproduza a Silver e forme um modelo dimensional íntegro.	Esquema e ordem das colunas; igualdade de valores e quantidade de linhas Silver–Gold; grão único; chaves sem órfãos; dimensões com chaves únicas; domínios das dimensões iguais aos domínios utilizados pelas fatos; coerência município–UF.	Cinco fatos, cinco dimensões, validadores individuais e mensagem `MODELO DIMENSIONAL GOLD: OK`.
Power BI	Evitar transformação analítica não documentada na visualização.	Consumo exclusivo da Gold; relacionamentos 1:* com filtro da dimensão para a fato; tipos esperados; 27 medidas DAX documentadas; escalas e unidades explicitadas.	Modelo semântico, arquivo de medidas e documentação de modelagem.

Fonte: Elaborado pelo autor a partir dos contratos de validação do projeto (2026).

D.2 Contratos por indicador

Tabela 22 – Controles específicos das tabelas Silver.

Indicador	**Grão único**	**Controles específicos**	**Resultado estrutural esperado**
Rendimento	`ANO+UF+ETAPA+REDE+INDICADOR`	17 anos; 27 UFs por ano; duas etapas; três indicadores; somente rede pública; valores entre 0 e 100; zero preservado; `-` convertido em ausência; soma Aprovação + Reprovação + Abandono aproximadamente igual a 100, considerando arredondamento; comparação dos 2.754 valores com a Bronze.	2.754 linhas; 162 por ano; nenhuma duplicidade.
TDI	`ANO+UF+ETAPA+REDE`	17 anos; 27 UFs por ano; duas etapas; somente rede pública; valores entre 0 e 100; preservação de zero; correspondência de arquivo, linha e coluna com a Bronze.	918 linhas; 54 por ano; nenhuma duplicidade.
IDEB	`ANO+UF+ETAPA+REDE`	Nove anos bienais; 27 UFs por etapa; rede `Publica (4)`; IDEB entre 0 e 10; aliases geográficos explícitos; seleção por `VL_OBSERVADO_AAAA`; arquivo, aba, linha e coluna conferidos.	486 linhas; 54 por ano; nenhuma duplicidade.
SAEB	`ANO+UF+ETAPA+REDE+DISCIPLINA`	Nove edições; duas etapas; duas disciplinas; proficiência entre 0 e 500; seleção de rede/localização/capital por edição; regra de zero de 2015; origem histórica de 2007/2009; uso do agregado oficial de UF em 2023; comparação dos 972 valores com as Bronzes.	972 linhas; 108 por ano; zero proficiências ausentes; nenhuma duplicidade.
PND	linha individual de origem dentro da população analítica	Total bruto, completude conjunta, condição `TP_PRES=555`, 27 UFs, 17 áreas, 750 municípios, mapeamento área-código, cinco resultados completos, `QT_ACERTOS` não negativo, preservação de valores publicados e comparação dos 759.140 registros com a Bronze.	759.140 linhas; nenhuma ausência nas cinco medidas; nenhuma linha de origem duplicada.

D.3 Campos de rastreabilidade

Tabela 23 – Metadados de proveniência preservados na Silver.

Indicador	**Campos de proveniência**
Rendimento	REDE_ORIGEM, LOCALIZACAO_ORIGEM, ARQUIVO_ORIGEM, LINHA_ORIGEM_BRONZE, COLUNA_ORIGEM
TDI	REDE_ORIGEM, LOCALIZACAO_ORIGEM, ARQUIVO_ORIGEM, LINHA_ORIGEM_BRONZE, COLUNA_ORIGEM
IDEB	GEOGRAFIA_ORIGEM, REDE_ORIGEM, ARQUIVO_ORIGEM, ABA_ORIGEM, LINHA_ORIGEM_BRONZE, COLUNA_ORIGEM
SAEB	REDE_ORIGEM, LOCALIZACAO_ORIGEM, CAPITAL_ORIGEM, ARQUIVO_ORIGEM, ABA_ORIGEM, LINHA_ORIGEM_BRONZE, COLUNA_ORIGEM, GRANULARIDADE_ORIGEM
PND	ARQUIVO_ORIGEM, GRANULARIDADE_ORIGEM, LINHA_ORIGEM_BRONZE

Fonte: Elaborado pelo autor (2026).

Na PND, LINHA_ORIGEM_BRONZE é um identificador técnico da posição do registro e não um identificador pessoal ou uma chave de negócio. Nas séries históricas, a combinação de arquivo, aba quando aplicável, linha e coluna permite localizar a célula que originou cada medida.

D.4 Falha explícita

O pipeline interrompe a execução quando encontra estrutura diferente do contrato auditado. Entre as condições de falha estão: arquivo ou coluna obrigatória ausente; cabeçalho em posição inesperada; categoria de rede desconhecida; UF não reconhecida; quantidade diferente de 27 UFs; duplicidade no grão; ano obrigatório ausente; valor não numérico fora dos marcadores documentados; domínio inválido; cardinalidade divergente; hash diferente; chave órfã; ou dimensão incompatível com as fatos.

Essa política evita que uma nova edição seja aceita silenciosamente com significado diferente. A incorporação de fonte ou layout novo exige nova auditoria, atualização explícita do mapeamento, execução dos validadores e registro da decisão metodológica.

D.5 Validação independente e limites da garantia

Os validadores Silver reconstroem os resultados esperados diretamente da Bronze, sem importar as funções do respectivo transformador. Os validadores Gold comparam os valores da Gold com a Silver e verificam os relacionamentos dimensionais. Essa separação reduz o risco de uma mesma implementação incorreta produzir e aprovar o resultado.

Os controles demonstram consistência interna, completude do recorte declarado, conformidade com as regras implementadas e rastreabilidade até os insumos. Eles não demonstram que toda informação oficial é livre de erro, que categorias históricas são metodologicamente idênticas ou que os dados excluídos seriam desnecessários para qualquer

outra pesquisa. A garantia é restrita ao escopo deste trabalho: rede pública, UFs, etapas e períodos declarados, além da população analítica definida para a PND.